

Analiza normalności rozkładu badanych makroskładników

Wstęp i Cel Analizy

Przed przystąpieniem do właściwych testów statystycznych (porównywania grup oraz badania korelacji) konieczne było sprawdzenie, czy rozkład zmiennych objaśnianych (zawartość białka, tłuszczu oraz laktozy) jest zgodny z rozkładem normalnym.

Badanie normalności rozkładu pozwala na poprawny dobór narzędzi statystycznych. W przypadku rozkładu normalnego stosuje się testy parametryczne (np. ANOVA, korelacja Pearsona). Gdy rozkład istotnie odbiega od normalnego, rekomendowane jest użycie metod nieparametrycznych.

Do weryfikacji hipotezy o normalności rozkładu wykorzystano **test Shapiro-Wilka**, w którym:

- Hipoteza zerowa (H_0): Zmienna ma rozkład normalny.
- Hipoteza alternatywna (H_1): Rozkład zmiennej różni się od rozkładu normalnego.

Podstawy matematyczne testu Shapiro-Wilka

Test Shapiro-Wilka opiera się na porównaniu wariancji wyznaczonej z próby z wariancją estymowaną na podstawie założeń o normalności rozkładu. Statystyka testowa W obliczana jest według następującego wzoru:

$$W = \frac{\left(\sum_{i=1}^n a_i x_{(i)}\right)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

gdzie:

- $x_{(i)}$ – to wartości próby uporządkowane rosnąco (tzw. statystyki pozycyjne),
- $\bar{x}$ – to średnia arytmetyczna z badanej próby,
- a_i – to stałe (współczynniki) wyznaczone na podstawie oczekiwanych wartości i macierzy kowariancji statystyk pozycyjnych ze standardowego rozkładu normalnego,
- n – to liczebność badanej próby.

Wartość statystyki W mieści się w przedziale $(0, 1]$. Wartości bliskie 1 oznaczają wysoką zgodność rozkładu empirycznego z krzywą Gaussa. Z kolei wartości istotnie mniejsze od 1 (co jest weryfikowane na podstawie wyliczonej wartości p) stanowią podstawę do odrzucenia hipotezy o normalności rozkładu.

Wyniki Testu Shapiro-Wilka

Wyniki testu dla poszczególnych makroskładników, wygenerowane za pomocą procedury UNIVARIATE w systemie SAS, przedstawiono w poniższej tabeli. Przyjęto standardowy poziom istotności $\alpha = 0.05$.

Tabela 1: Wyniki testu normalności Shapiro-Wilka

Zmienna	Statystyka W	Wartość p
Białko (Protein)	0.9487	$p < 0.0001$
Tłuszcz (Fat)	0.9862	$p = 0.0003$
Laktoza (Lactose)	0.9489	$p < 0.0001$


Ponieważ dla wszystkich trzech zmiennych wartość p jest znacznie mniejsza od przyjętego poziomu istotności ($p < 0.05$), **odrzucaamy hipotezę zerową**. Stwierdzamy, że rozkłady badanych makroskładników nie są normalne.

Analiza Wizualna (Histogramy)

Brak normalności rozkładu potwierdza również analiza wizualna nałożona na krzywą Gaussa.

Rozkład Białka


Jak widać na poniższym wykresie, rozkład białka charakteryzuje się asymetrią (skośnością prawostronną) – większość wyników skupia się wokół niższych wartości, z wyraźnym długim "ogonem" obserwacji skrajnie wysokich.



Rysunek 1: Histogram rozkładu dla zmiennej Białko na tle krzywej normalnej

Rozkład Tłuszczu


W przypadku tłuszczu odstępstwo od normalności przejawia się w postaci asymetrii prawostronnej (dodatniej skośności). Choć rozkład wizualnie może przypominać krzywą normalną, najwyższa liczebność obserwacji jest przesunięta w lewo względem średniej teoretycznej, a po prawej stronie widoczny jest charakterystyczny „ogon” wyższych wartości. Przy dużej liczebności próby ($n = 442$), te subtelne odchylenia od symetrii zostały jednoznacznie wykazane w teście Shapiro-Wilka ($p = 0,0003$).



Rysunek 2: Histogram rozkładu dla zmiennej Tłuszcz na tle krzywej normalnej

Rozkład Laktozy

W przypadku laktozy odstępstwo od normalności ma inny charakter. Zmienna ta wykazuje wyraźną kurtozę dodatnią. Oznacza to, że obserwacje są niezwykle silnie skoncentrowane wokół średniej (w wąskim przedziale od 7.1 do 7.3), a krzywa gęstości jest znacznie bardziej "wysmukła" niż zakłada to model idealnego rozkładu normalnego. Zjawisko to potwierdza silną biologiczną regulację ciśnienia osmotycznego w gruczole mlekowym.



Rysunek 3: Histogram rozkładu dla zmiennej Laktoza wykazujący kurtozę dodatnią