

Analiza wpływu wieku mleka na skład mleka kobiecego

Wstęp

Skład mleka kobiecego ulega zmianom w trakcie laktacji, co może mieć istotne znaczenie dla rozwoju noworodka. W szczególności interesujące jest, w jaki sposób wraz z upływem czasu zmienia się zawartość podstawowych makroskładników, takich jak białko, tłuszcz oraz laktoza.

Celem niniejszej analizy jest zbadanie zależności pomiędzy wiekiem mleka, wyrażonym jako liczba dni od porodu (Age of Milk [Days Since Birth]), a jego składem chemicznym. Analizie poddano dane obserwacyjne obejmujące próbki mleka, dla których dostępne były następujące zmienne: zawartość tłuszczu (Fat [g/dL]), białka (Protein [g/dL]) oraz laktozy (Lactose [g/dL]).

Dane pochodzą z artykułu opublikowanego w czasopiśmie *PLOS ONE* [1]. W analizie uwzględniono obserwacje dla mleka o wieku do 600 dni.

W analizie zastosowano współczynnik korelacji rang Spearmana do oceny zależności między wiekiem mleka a jego składem, regresję liniową w celu określenia kierunku i wielkości zmian oraz test Kruskala-Wallisa do porównania grup wieku mleka. Analizę przeprowadzono z wykorzystaniem oprogramowania R.

Hipotezy

Dla każdej analizowanej zmiennej (białko, tłuszcz, laktoza) sformułowano następujące hipotezy statystyczne dotyczące zależności od wieku mleka:

- $H_0 : r_s = 0$ (brak zależności między wiekiem mleka a daną zmienną)
- $H_1 : r_s \neq 0$ (istnieje zależność między wiekiem mleka a daną zmienną)

Weryfikację hipotez przeprowadzono z wykorzystaniem współczynnika korelacji rang Spearmana r_s . Decyzję o odrzuceniu hipotezy zerowej podejmowano na podstawie wartości p przy poziomie istotności $\alpha = 0.05$.

Podstawy teoretyczne

Korelacja Spearmana

Korelacja rang Spearmana służy do oceny monotonicznej zależności między dwiema zmiennymi.

Współczynnik korelacji Spearmana definiuje się następująco:

$$r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

gdzie:

- d_i – różnica między rangami odpowiadających sobie wartości cech x_i i y_i ,
- n – liczba par obserwacji.

Wartość współczynnika r_s należy do przedziału $[-1, 1]$. Dodatnie wartości wskazują na zależność rosnącą, ujemne na malejącą, natomiast wartości bliskie zeru oznaczają brak wyraźnej zależności.

W celu oceny istotności statystycznej wykorzystuje się statystykę testową:

$$t = \frac{r_s \sqrt{n-2}}{\sqrt{1-r_s^2}}$$

która dla dużych prób ma w przybliżeniu rozkład t-Studenta z $n - 2$ stopniami swobody.

Istotność statystyczną ocenia się na podstawie wartości p (p-value), czyli prawdopodobieństwa uzyskania obserwowanego wyniku przy założeniu prawdziwości hipotezy zerowej. Jeśli $p < \alpha$, odrzuca się hipotezę zerową o braku zależności.

Regresja liniowa

Regresja liniowa służy do opisu wpływu zmiennej niezależnej x na zmienną zależną y . W niniejszej pracy zmienną niezależną jest wiek mleka, natomiast zmienną zależną jest zawartość analizowanego składnika (białka, tłuszczu lub laktozy).

Model regresji ma postać:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

gdzie:

- β_0 – wyraz wolny (wartość y dla $x = 0$),
- β_1 – współczynnik kierunkowy (zmiana y przy jednostkowej zmianie x),
- ε – składnik losowy.

Parametry modelu wyznacza się metodą najmniejszych kwadratów. Współczynnik kierunkowy oblicza się ze wzoru:

$$\beta_1 = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}$$

a wyraz wolny jako:

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

Interpretacja współczynnika kierunkowego:

- $\beta_1 > 0$ oznacza wzrost wartości y wraz ze wzrostem x ,
- $\beta_1 < 0$ oznacza spadek wartości y wraz ze wzrostem x .

Stopień dopasowania modelu opisuje współczynnik determinacji:

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

gdzie:

- $SS_{\text{res}} = \sum (y_i - \hat{y}_i)^2$ – suma kwadratów reszt,
- $SS_{\text{tot}} = \sum (y_i - \bar{y})^2$ – całkowita zmienność danych.

Wartość R^2 należy do przedziału $[0, 1]$ i określa, jaka część zmienności zmiennej zależnej jest wyjaśniana przez model regresji.

Test Kruskala-Wallisa

Test Kruskala-Wallisa jest nieparametrycznym odpowiednikiem jednoczynnikowej analizy wariancji i służy do porównania więcej niż dwóch grup. W niniejszej pracy wykorzystano go do oceny, czy zawartość analizowanych składników różni się między grupami wieku mleka.

Statystyka testowa ma postać:

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k \frac{R_i^2}{n_i} - 3(N+1)$$

gdzie:

- R_i – suma rang w i -tej grupie,
- n_i – liczność i -tej grupy,
- N – całkowita liczba obserwacji,
- k – liczba porównywanych grup.

Hipotezy testowe mają postać:

- H_0 : brak różnic między grupami,
- H_1 : co najmniej jedna grupa różni się od pozostałych.

Dla dużych prób statystyka H ma w przybliżeniu rozkład chi-kwadrat:

$$H \sim \chi_{k-1}^2$$

gdzie $df = k - 1$ oznacza liczbę stopni swobody testu.

Istotność statystyczną ocenia się na podstawie wartości p wyznaczonej z rozkładu chi-kwadrat. Jeśli $p < \alpha$, odrzuca się hipotezę zerową, co oznacza, że istnieją istotne różnice między grupami.

Statystyka opisowa

Zmienna	Min	Q1	Mediana	Średnia	Q3	Max
Wiek mleka [dni]	1.0	38.0	88.0	120.4	174.0	573.0
Tłuszcz	0.2	3.0	3.5	3.522	4.0	7.1
Białko	0.6	0.9	1.0	1.071	1.2	2.1
Laktoza	6.3	7.1	7.2	7.212	7.3	8.2

Tabela 1: Statystyki opisowe dla danych do 600 dni

Na podstawie statystyki opisowej można zauważyć, że średnia zawartość białka wynosi 1.071, średnia zawartość tłuszczu 3.522, a średnia zawartość laktozy 7.212.

Analiza białka

Dla zawartości białka obliczono współczynnik korelacji rang Spearmana.

W pierwszym kroku każdej obserwacji przypisano rangi dla zmiennej wieku mleka oraz zawartości białka. Następnie obliczono różnice rang d_i oraz ich kwadraty d_i^2 , które wykorzystano do wyznaczenia współczynnika korelacji.

Otrzymano:

$$r_s = -0.5389, \quad p < 0.001$$

Na podstawie wartości p odrzucono hipotezę zerową H_0 o braku zależności.

Wartość r_s wskazuje na umiarkowanie silną ujemną zależność między wiekiem mleka a zawartością białka, co oznacza, że wraz ze wzrostem wieku mleka zawartość białka maleje.

Model regresji liniowej dla zawartości białka ma postać:

$$y = 1.1549 - 0.0007x$$

gdzie x oznacza wiek mleka w dniach, a y zawartość białka.


Współczynnik kierunkowy jest ujemny, co oznacza, że wraz ze wzrostem wieku mleka zawartość białka maleje.

Dopasowanie modelu opisuje współczynnik determinacji:


$$R^2 = 0.1442$$

Oznacza to, że wiek mleka wyjaśnia około 14% zmienności zawartości białka. Wartość $p < 0.001$ wskazuje, że zależność ta jest istotna statystycznie.

Wniosek: wraz ze wzrostem wieku mleka zawartość białka maleje. Zależność ta jest istotna statystycznie, jednak jej siła jest umiarkowana, co wskazuje, że wiek mleka wyjaśnia tylko część zmienności zawartości białka.



Rysunek 1: Zależność zawartości białka od wieku mleka



Rysunek 2: Histogram zawartości białka

Analiza tłuszczu

Dla zawartości tłuszczu obliczono współczynnik korelacji rang Spearmana.

W pierwszym kroku każdej obserwacji przypisano rangi dla zmiennej wieku mleka oraz zawartości tłuszczu. Następnie obliczono różnice rang d_i oraz ich kwadraty d_i^2 , które wykorzystano do wyznaczenia współczynnika korelacji.

Otrzymano:

$$r_s = 0.1236, \quad p < 0.001$$

Na podstawie wartości p odrzucono hipotezę zerową H_0 o braku zależności.

Wartość r_s wskazuje na słabą dodatnią zależność między wiekiem mleka a zawartością tłuszczu, co oznacza, że wraz ze wzrostem wieku mleka zawartość tłuszczu nieznacznie rośnie.

Model regresji liniowej dla zawartości tłuszczu ma postać:

$$y = 3.3746 + 0.001225x$$

gdzie x oznacza wiek mleka w dniach, a y zawartość tłuszczu.


Współczynnik kierunkowy jest dodatni, co oznacza, że wraz ze wzrostem wieku mleka zawartość tłuszczu rośnie. Wzrost ten jest jednak niewielki.

Dopasowanie modelu opisuje współczynnik determinacji:


$$R^2 = 0.0249$$

Oznacza to, że wiek mleka wyjaśnia około 2.5% zmienności zawartości tłuszczu. Wartość $p < 0.001$ wskazuje, że zależność ta jest istotna statystycznie.

Wniosek: wraz ze wzrostem wieku mleka zawartość tłuszczu nieznacznie rośnie. Zależność ta jest istotna statystycznie, jednak jej siła jest słaba, co wskazuje, że wiek mleka w niewielkim stopniu wyjaśnia zmienność zawartości tłuszczu.



Rysunek 3: Zależność zawartości tłuszczu od wieku mleka



Rysunek 4: Histogram zawartości tłuszczu

Analiza laktozy

Dla zawartości laktozy obliczono współczynnik korelacji rang Spearmana.

W pierwszym kroku każdej obserwacji przypisano rangi dla zmiennej wieku mleka oraz zawartości laktozy. Następnie obliczono różnice rang d_i oraz ich kwadraty d_i^2 , które wykorzystano do wyznaczenia współczynnika korelacji.

Otrzymano:

$$r_s = -0.0988, \quad p < 0.001$$

Na podstawie wartości p odrzucono hipotezę zerową H_0 o braku zależności.

Wartość r_s wskazuje na słabą ujemną zależność między wiekiem mleka a zawartością laktozy, co oznacza, że wraz ze wzrostem wieku mleka zawartość laktozy nieznacznie

maleje.

Model regresji liniowej dla zawartości laktozy ma postać:

$$y = 7.2273 - 0.000123x$$

gdzie x oznacza wiek mleka w dniach, a y zawartość laktozy.


Współczynnik kierunkowy jest ujemny, co oznacza, że wraz ze wzrostem wieku mleka zawartość laktozy maleje. Zmiana ta jest jednak bardzo niewielka.

Dopasowanie modelu opisuje współczynnik determinacji:


$$R^2 = 0.004$$

Oznacza to, że wiek mleka wyjaśnia około 0.4% zmienności zawartości laktozy. Wartość $p < 0.05$ wskazuje, że zależność ta jest istotna statystycznie.

Wniosek: wraz ze wzrostem wieku mleka zawartość laktozy nieznacznie maleje. Zależność ta jest istotna statystycznie, jednak jej siła jest bardzo słaba, co wskazuje, że wiek mleka praktycznie nie wyjaśnia zmienności zawartości laktozy.



Rysunek 5: Zależność zawartości laktozy od wieku mleka



Rysunek 6: Histogram zawartości laktozy

Test Kruskala-Wallisa

W celu porównania zawartości makroskładników w zależności od wieku mleka zastosowano test Kruskala-Wallisa. Dane podzielono na cztery grupy:

- mleko młode (0–30 dni),
- mleko średnie (31–90 dni),
- mleko dojrzałe (91–200 dni),
- mleko późne (201–600 dni).



Statystykę testową H obliczono na podstawie rang obserwacji, a następnie porównano z rozkładem chi-kwadrat o $df = k - 1 = 3$ stopniach swobody.

Otrzymano następujące wyniki:

- Białko: $\chi^2 = 371.08$, $df = 3$, $p < 2.2 \cdot 10^{-16}$
- Tłuszcz: $\chi^2 = 28.138$, $df = 3$, $p = 3.398 \cdot 10^{-6}$
- Laktoza: $\chi^2 = 16.522$, $df = 3$, $p = 0.0008863$

Ponieważ dla wszystkich analizowanych składników wartości p są mniejsze od poziomu istotności $\alpha = 0.05$, odrzucono hipotezę zerową o braku różnic między grupami.

Wyniki wskazują, że zawartość białka, tłuszczu i laktozy różni się istotnie pomiędzy poszczególnymi etapami laktacji, przy czym największe różnice zaobserwowano dla zawartości białka.



Wnioski końcowe

Na podstawie przeprowadzonej analizy sformułowano następujące wnioski:

- zawartość białka maleje wraz z wiekiem mleka i wykazuje umiarkowanie silną zależność,
- zawartość tłuszczu nieznacznie rośnie, jednak zależność ta jest słaba,
- zawartość laktozy pozostaje względnie stabilna, z bardzo słabą tendencją malejącą,
- test Kruskala-Wallisa potwierdza istotne statystycznie różnice między grupami wieku mleka dla wszystkich analizowanych składników.

Najsilniejszą zależność zaobserwowano dla białka, natomiast tłuszcz i laktoza wykazują zmiany znacznie słabsze, mimo że pozostają one istotne statystycznie.

Literatura

- [1] Changes in human milk composition during lactation, PLOS ONE, 2019.
<https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0210610>
- [2] L. Gajek, M. Kałuszka, Wnioskowanie statystyczne, Wydawnictwa Naukowo-Techniczne, Warszawa, 1996.
- [3] W. Kordecki, Rachunek prawdopodobieństwa i statystyka matematyczna, Oficyna Wydawnicza GiS, Wrocław, 2010.
- [4] P. Biecek, Przewodnik po pakiecie R, Oficyna Wydawnicza GiS, Wrocław, 2017.