



WYDZIAŁ FIZYKI TECHNICZNEJ
I MATEMATYKI STOSOWANEJ

SPRAWOZDANIE Z PROJEKTU SPECJALNOŚCIOWEGO

Matematyka studia licencjackie

Tytuł projektu: Analiza danych MilkyBase

Autorzy: Veronika Rykoic, Jakub Pawluczuk, Martyna Dziewic, Aleksandra Grześ

Opiekun projektu: dr inż. Magdalena Chmara

Gdańsk, 12 czerwca 2026 r.

Spis treści

1	Cel projektu	1
2	Opis projektu	2
3	Wnioski	3
3.1	Wnioski z etapu przygotowania i obróbki danych	3
3.2	Wnioski z analizy statystycznej	3
4	Podział pracy	5
5	Bibliografia	6
6	Uwagi	8
7	Termin prezentacji	8
8	Załączniki	8

1 Cel projektu

Przystępując do pracy, naszym pierwszym zadaniem było dokładne zapoznanie się z surową bazą danych. Konieczne było przeanalizowanie obszernej, bardzo trudnej do analizy struktury zgromadzonych informacji, ocena ich jakości oraz wyznaczenie konkretnego kierunku badawczego, który nadałby kierunek postępowania w ramach projektu.

Po dyskusjach wewnętrznych oraz skonsultowaniu się z opiekunem projektu ustalono, że głównym celem projektu będzie analiza statystyczna składu mleka kobiecego na podstawie danych pochodzących z jednego z artykułów wchodzącego w skład szerszej bazy danych. Ustalono, że głównym kierunkiem pracy nad projektem będzie identyfikacja czynników mogących wpływać na zawartość podstawowych makroskładników mleka, tj. białka, tłuszczu i laktozy. W szczególności badano zależność składu mleka od:

- wieku mleka (czasu trwania laktacji),
- wieku matki,
- czasu trwania ciąży oraz wyniku porodu.

Dodatkowym celem było określenie bezpośrednich zależności pomiędzy poszczególnymi makroskładnikami oraz analiza gęstości energetycznej pokarmu. Przeprowadzone badania miały w efekcie umożliwić nam obiektywną ocenę tego, które z analizowanych czynników w największym stopniu wpływają na naturalną zmienność składu mleka kobiecego.

2 Opis projektu

Projekt dotyczył analizy składu mleka kobiecego oraz czynników, które mogą wpływać na jego zawartość. Prace rozpoczęto od zapoznania się z bazą MilkyBase, opisaną w artykule *MilkyBase, a database of human milk composition as a function of maternal-, infant- and measurement conditions* [1]. Zbiór ten obejmował zarówno metadane badań, takie jak źródło, region i metode pomiarową, jak również informacje dotyczące matki, dziecka, warunków przechowywania próbek oraz składu mleka.

W pierwszym etapie przeanalizowano strukturę pliku Excel oraz sposób w jaki znajdują się w nim informacje. Skoroszyt składał się z arkusza głównego *Master* oraz arkuszy pomocniczych z objaśnieniami skrótów i kodów. W arkuszu głównym dane często były połączone w jedną komórkę oraz przedstawione w postaci skrótów i odwołań tekstowych.

Szczególnym utrudnieniem okazał się zapis w kolumnach *Condition* oraz *Component*, gdzie informacje z poszczególnych badań były zagregowane wewnątrz pojedynczych komórek. Z tego względu przeprowadzono deagregację w programie SAS, polegającą na rozdzieleniu tych zapisów na osobne kolumny.

Po wykonaniu obróbki sprawdzono kompletność uzyskanych zmiennych. Wykazano, że wiele kolumn zawierało bardzo mało obserwacji, co ograniczało ich przydatność w dalszym opracowaniu statystycznym. Dlatego właściwą część projektu oparto na danych pochodzących z artykułu *Macronutrient Variability in Human Milk From Donors to a Milk Bank: Implications for Feeding Preterm Infants* [2]. Był to najbardziej kompletny fragment zbioru, zawierający informacje o stężeniu białka, tłuszczu oraz laktozy.

W dalszej części pracy wykorzystano wybrany zestaw danych do przeprowadzenia analiz statystycznych. Opracowano charakterystykę badanych zmiennych oraz sprawdzono rozkład głównych makroskładników mleka kobiecego.

Następnie oceniono wpływ wieku matki na skład mleka, zależności pomiędzy makroskładnikami oraz zmiany składu mleka wraz z jego wiekiem. W kolejnych etapach sprawdzono, czy zawartość białka, tłuszczu i laktozy różni się w zależności od czasu trwania ciąży oraz wyniku porodu. Przeprowadzono również analizę zmian w czasie oraz oceniono gęstość energetyczną mleka, porównując grupy *Term* i *Preterm*.

Wyniki przedstawiono w formie tabel, wykresów oraz opisów statystycznych, co pozwoliło uporządkować najważniejsze zależności zaobserwowane w analizowanym zbiorze danych.

3 Wnioski

3.1 Wnioski z etapu przygotowania i obróbki danych

Doświadczenia zebrane podczas pracy z pierwotną bazą MilkyBase wyraźnie pokazują, że rzeczywiste, obszerne zbiory danych biologicznych i medycznych rzadko są gotowe do bezpośredniej analizy statystycznej. Etap zrozumienia, czyszczenia i przygotowania danych stanowił kluczowy element naszego projektu. Z tej fazy prac płyną następujące wnioski ogólne:

- **Problem agregacji informacji:** Zapisywanie wielu różnych parametrów, warunków i jednostek w pojedynczych komórkach arkusza kalkulacyjnego uniemożliwia wykorzystanie standardowych metod analitycznych. Dopiero deagregacja, przeprowadzona przy użyciu oprogramowania SAS, pozwoliła na rozbitcie tych informacji na odrębne, gotowe do zrozumienia zmienne.
- **Niekompletność danych:** Zwiększenie rozmiarów bazy (po deagregacji do ponad 700 kolumn) ujawniło różnice w kompletności informacji. Ponad 500 badanych cech posiadało mniej niż 10 obserwacji. Wymusiło to konieczność redukcji analizowanego zbioru i skupienia się wyłącznie na najlepiej udokumentowanych makroskładnikach (białko, tłuszcz, laktoza).
- **Niespójność formatów i struktury:** Obecność odwołań tekstowych (np. *!John_026_Prot*) w miejscach, w których spodziewamy się wartości liczbowych stanowi przeszkodę w badaniach. Próba analizy danych z różnych, niejednorodnych metodologicznie badań niesie ryzyko wyciągnięcia błędnych wniosków.

Podsumowując, powyższe trudności skłoniły nas do odrzucenia niespójnych fragmentów bazy na rzecz wyselekcjonowania rzetelnego, jednorodnego podzbioru (pochodzącego z artykułu z *PLOS ONE*) [2]. Wniosek jest jednoznaczny: jakość i wiarygodność wyników analizy statystycznej zależy w pierwszej kolejności od świadomej selekcji oraz właściwego przygotowania materiału, który będziemy poddawać analizie.

3.2 Wnioski z analizy statystycznej

Na podstawie przeprowadzonych analiz statystycznych sformułowaliśmy następujące wnioski końcowe dotyczące składu mleka kobiecego:

- **Rozkład makroskładników:** Nasze badania pokazały, że żaden z głównych makroskładników (białko, tłuszcz, laktoza) nie ma rozkładu normalnego. Dane były często

asymetryczne (np. wyraźne skupienie wyników wokół jednej wartości dla laktozy), co w pewnych przypadkach wymuszało konieczność korzystania z testów nieparametrycznych w dalszej części projektu.

- **Wpływ wieku matki:** Gdy podzieliliśmy pacjentki na dwie szerokie grupy (poniżej i powyżej 30 lat), nie zauważyliśmy żadnych istotnych różnic w składzie ich mleka. Taka różnica pojawiła się dopiero, gdy porównane zostały ze sobą skrajne grupy wiekowe – okazało się, że matki starsze (powyżej 35. roku życia) mają w mleku nieco więcej białka niż matki bardzo młode (do 25 lat).
- **Dynamika laktacji (wiek mleka):** Czas, jaki upłynął od porodu, okazał się czynnikiem najsilniej wpływającym na zawartość białka. Tuż po porodzie jest go najwięcej, a z czasem jego poziom dość szybko spada, by później się ustabilizować. Zmiany te nie mają jednak prostego, liniowego charakteru, co potwierdziły nasze wykresy i ocena dopasowania modeli.
- **Stabilność zawartości tłuszczu i laktozy w czasie:** W przeciwieństwie do białka, poziom tłuszczu i laktozy zmienia się w czasie tylko w minimalnym stopniu. Choć nasze testy wykazywały bardzo słabe trendy (lekki wzrost dla tłuszczu i spadek dla laktozy), to modele regresji pokazały, że sam upływ czasu niemal w ogóle nie tłumaczy tych zmian. Ich poziom prawdopodobnie zależy od innych, indywidualnych cech organizmu matki.
- **Wpływ dojrzałości noworodka i wyniku porodu:** Sprawdzając, czy czas trwania ciąży i wynik porodu wpływają na skład mleka, zauważyliśmy istotne różnice tylko w przypadku laktozy. Jej poziom był zauważalnie niższy u matek, które straciły dziecko (grupa Deceased). Z kolei zawartość tłuszczu i białka pozostawała na bardzo zbliżonym poziomie bez względu na to, czy poród nastąpił w terminie, był przedwczesny, czy zakończył się śmiercią dziecka.
- **Gęstość energetyczna:** Nasze obliczenia nie potwierdziły, aby przedwczesny poród znacząco wpływał na kaloryczność mleka. Mleko matek wcześniaków było wprawdzie minimalnie bardziej kaloryczne, ale różnica ta nie okazała się statystycznie istotna. Co więcej, zauważyliśmy, że w ciągu całego pierwszego roku laktacji gęstość energetyczna mleka jest bardzo stabilna i wzrasta tylko nieznacznie.

Podsumowując, największy wpływ na skład mleka ma czas, jaki upłynął od porodu – jednak zjawisko to dotyczy przede wszystkim białka. Poziom tłuszczu, laktozy oraz ogólna kaloryczność mleka są parametrami znacznie bardziej stabilnymi. Nie zmieniają się one drastycznie z upływem czasu i nie zależą w tak dużym stopniu ani od wieku matki, ani od momentu rozwiązania ciąży.

4 Podział pracy

Autor	Zakres wykonanych prac
Veronika Rykoic	Utworzenie repozytorium GitHub, przeprowadzenie deagregacji danych z bazy MilkyBase w programie SAS, wykonanie analizy wpływu wieku mleka na skład mleka kobiecego w programie R, w tym przeprowadzenie testu Kruskala–Wallisa dla czterech grup wieku mleka, oraz praca nad ogólnym sprawozdaniem projektu specjalnościowego.
Jakub Pawluczuk	Napisanie wstępu do projektu wraz z opisem decyzji, które doprowadziły do obrania takiego kierunku projektu. Przeprowadzenie głównej części prezentacji. Wykonanie w programie SAS testów mających na celu zweryfikowanie normalności rozkładów składników, wpływu wieku matki na skład mleka oraz zależności pomiędzy zawartościami składników w mleku.
Martyna Dziewic	Obliczono kaloryczność mleka na podstawie jego składu, następnie wykonano analizę, jak energia mleka zmienia się z upływem dni w pierwszym roku po porodzie oraz czy różni się ono u matek wcześniaków i dzieci urodzonych o czasie. Potrzebną analizę, histogram oraz wykresy zrobiono w programie Python.
Aleksandra Grześ	Przeprowadzenie w programie R analizy zawartości składników mleka matki oraz analizy zmiany składu mleka matki w czasie, oba w zależności od czasu trwania ciąży i wyniku porodu, korzystając m. in. z testu Kruskala-Wallisa oraz stosując analizę post-hoc; wykonanie oceny jakościowej użytych modeli.

5 Bibliografia

- [1] MilkyBase, a database of human milk composition as a function of maternal-, infant- and measurement conditions. Figshare.
https://figshare.com/collections/MilkyBase_a_database_of_human_milk_composition_as_a_function_of_maternal-_infant-_and_measurement_conditions/6160191/1
- [2] Macronutrient Variability in Human Milk From Donors to a Milk Bank: Implications for Feeding Preterm Infants.
<https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0210610>
- [3] L. Gajek, M. Kałuszka, Wnioskowanie statystyczne, Wydawnictwa Naukowo-Techniczne, Warszawa, 1996.
- [4] Majewski, J. Wykład 7: Testy nieparametryczne. Statystyka w medycynie. Akademia Górniczo-Hutnicza im. Stanisława Staszica w Krakowie.
<https://kompilatory.agh.edu.pl/statwmed/wyklady/WFiIS-STATwMED-7-\Testy-nieparametryczne.pdf>
- [5] W. Kordecki, Rachunek prawdopodobieństwa i statystyka matematyczna, Oficyna Wydawnicza GiS, Wrocław, 2010.
- [6] Wikipedia, *Współczynnik korelacji rang Spearmana*.
https://pl.wikipedia.org/wiki/Wsp%C3%B3%C5%82czynnik_korelacji_rang_Spearmana
- [7] Mfiles, *Współczynnik korelacji rang Spearmana*.
https://mfiles.pl/pl/index.php/Wsp%C3%B3%C5%82czynnik_korelacji_rang_Spearmana
- [8] Wikipedia, *Regresja liniowa*.
<https://pl.wikipedia.org/wiki/Regresja liniowa>
- [9] Wikipedia contributors, *Local regression*, https://en.wikipedia.org/wiki/Local_regression
- [10] Data Science, *Metryki regresji*.
https://datascience.com.pl/uczenie_maszynowe_wstep/metryki_ml/regresja.html

-
- [11] Srivastava, S., *Evaluating Model Performance: Understanding MAE, MSE, RMSE and R^2 Score*.
[https://medium.com/@srivastavashivansh8922/evaluating-model-\](https://medium.com/@srivastavashivansh8922/evaluating-model-performance-understanding-mae-mse-rmse-and-r%C2%B2-score-5516e10fe8d6)
[performance-understanding-mae-mse-rmse-and-r%C2%B2-score-5516e10fe8d6](https://medium.com/@srivastavashivansh8922/evaluating-model-performance-understanding-mae-mse-rmse-and-r%C2%B2-score-5516e10fe8d6)
[https://www.naukowiec.org/wzory/statystyka/test-kruskala-wallisa_121.](https://www.naukowiec.org/wzory/statystyka/test-kruskala-wallisa_121.html)
[html](https://www.naukowiec.org/wzory/statystyka/test-kruskala-wallisa_121.html)
- [12] Schultz, S. *The Concise Encyclopedia of Statistics*. Springer, 2008.
[https://www.stewartschultz.com/statistics/books/The%20Concise%](https://www.stewartschultz.com/statistics/books/The%20Concise%20Encyclopedia%20of%20Statistics.pdf)
[20Encyclopedia%20of%20Statistics.pdf](https://www.stewartschultz.com/statistics/books/The%20Concise%20Encyclopedia%20of%20Statistics.pdf)
- [13] ANOVA Kruskala-Wallis
https://manuals.pqstat.pl/statpqpl:porown3grpl:nparpl:anova_kwpl
- [14] P. Biecek, Przewodnik po pakiecie R, Oficyna Wydawnicza GiS, Wrocław, 2017.
- [15] Zapotrzebowanie kaloryczne – jak je obliczyć i od czego zależy?
[https://ostrovit.com/pl/blog/zapotrzebowanie-kaloryczne-jak-je-obliczyc\](https://ostrovit.com/pl/blog/zapotrzebowanie-kaloryczne-jak-je-obliczyc--od-czego-zalezy-1620652901.html)
[-od-czego-zalezy-1620652901.html](https://ostrovit.com/pl/blog/zapotrzebowanie-kaloryczne-jak-je-obliczyc--od-czego-zalezy-1620652901.html)
- [16] MilkyBase, a database of human milk composition as a function of maternal-, infant- and measurement conditions.
<https://pmc.ncbi.nlm.nih.gov/articles/PMC9463137/>
- [17] ANOVA czyli analiza wariancji w pracy magisterskiej. Poradnik od a do z
[https://magisterna5.pl/anova-analiza-wariancji-w-pracy-magisterskiej/](https://magisterna5.pl/anova-analiza-wariancji-w-pracy-magisterskiej/#Krok_4-_Testy_post_hoc_%E2%80%93_czyli_kto_sie_rozni_od_kogo)
[#Krok_4-_Testy_post_hoc_%E2%80%93_czyli_kto_sie_rozni_od_kogo](https://magisterna5.pl/anova-analiza-wariancji-w-pracy-magisterskiej/#Krok_4-_Testy_post_hoc_%E2%80%93_czyli_kto_sie_rozni_od_kogo)

6 Uwagi

W trakcie realizacji projektu wykorzystano następujące narzędzia informatyczne:

- **R** – przeprowadzanie analiz statystycznych, testów statystycznych oraz przygotowanie wykresów,
- **Python** – przetwarzanie danych oraz wykonywanie analiz statystycznych,
- **SAS** – deagregacja danych oraz wykonywanie analiz statystycznych,
- **Microsoft Excel** – przeglądanie i organizacja danych,
- **GitHub** – przechowywanie plików projektowych i współpraca w zespole,
- **L^AT_EX** – przygotowanie końcowej wersji sprawozdania.
- **Narzędzia sztucznej inteligencji (AI)** – wsparcie w przygotowaniu kodu oraz redakcji sprawozdania.

7 Termin prezentacji

Prezentacja została przeprowadzona 27 maja 2026 roku na seminarium specjalnościowym.

8 Załączniki

1. Sprawozdanie końcowe z projektu specjalnościowego.
2. Repozytorium GitHub zawierające kody źródłowe oraz arkusze danych wykorzystane podczas realizacji projektu.
3. Skrypty programów R, SAS i Python wykorzystane do przetwarzania danych i analiz statystycznych.