



WYDZIAŁ FIZYKI TECHNICZNEJ
I MATEMATYKI STOSOWANEJ

SPRAWOZDANIE Z PROJEKTU SPECJALNOŚCIOWEGO

Matematyka studia licencjackie

Tytuł projektu: Analiza danych MilkyBase

Autorzy: Veronika Rykoic, Jakub Pawluczuk, Martyna Dziewic, Aleksandra Grześ

Opiekun projektu: dr inż. Magdalena Chmara

Gdańsk, 8 czerwca 2026 r.

Spis treści

1	Wstęp	1
1.1	Zakres i charakterystyka danych.....	1
1.2	Potencjalne problemy i ograniczenia analizy	2
1.3	Wstępna obróbka i deagregacja danych	3
1.4	Analiza kompletności danych.....	4
1.5	Wybór ostatecznego zbioru badawczego.....	4
2	Charakterystyka analizowanego zbioru danych	5
2.1	Pochodzenie danych	5
2.2	Opis badanych zmiennych.....	5
2.3	Struktura próby badawczej.....	6
3	Podstawy teoretyczne	7
3.1	Analiza rozkładu danych	7
3.2	Test istotności dla różnicy dwóch średnich	8
3.3	Współczynnik korelacji rang Spearmana	9
3.4	Regresja liniowa	10
3.5	Metoda wygładzania LOESS	11
3.6	Metryki służące do oceny jakości modeli	12
3.7	Test Kruskala-Wallisa	13
3.8	Test Dunna z korektą Bonferroniego.....	14
4	Wyniki	15
4.1	Analiza normalności rozkładu badanych makroskładników w mleku kobiecy	15
4.2	Analiza składników mleka matki w zależności od wieku matki	22
4.3	Analiza współzależności makroskładników	25
4.4	Analiza wpływu wieku mleka na skład mleka kobiecego	26
4.5	Analiza zawartości składników mleka matki w zależności od czasu trwania ciąży i wyniku porodu	36
4.6	Analiza zmiany składu mleka w czasie w zależności od czasu trwania ciąży i wyniku porodu	45
4.7	Analiza porównawcza gęstości energetycznej mleka (Term vs Preterm). ..	52
5	Wnioski	54
5.1	Wnioski z etapu przygotowania i obróbki danych	54
5.2	Wnioski z analizy statystycznej.....	55
6	Bibliografia	56

1 Wstęp

1.1 Zakres i charakterystyka danych

Czego dotyczą dane?

Zebrane dane przedstawiają informacje dotyczące badań nad ludzkim mlekiem. Zestaw obejmuje zarówno metadane dotyczące badań, jak i parametry opisujące matkę, dziecko, warunki przechowywania oraz skład mleka.

1.1.1 Jakie informacje zawiera zbiór?

W pliku znajdują się następujące kategorie danych:

- **Źródło badania** (*Source*),
- **Region/kraj przeprowadzenia badania** (*Region*),
- **Metoda pomiarowa** (*Meas Method*),
- **Informacje o matce i dziecku oraz warunkach** (*Condition*):
 - dane matki (np. tydzień ciąży, wiek, BMI, problemy zdrowotne, deficyty witamin),
 - dieta matki (np. wegetarianizm, spożycie mleka, codzienne spożycie kalorii oraz witamin i minerałów),
 - dane dziecka (np. masa ciała, wzrost, problemy zdrowotne),
 - warunki przechowywania mleka (czas pobrania próbki, temperatura i czas przechowywania).
- **Skład mleka** (*Component*): zawartość witamin, tłuszczów, cukrów oraz minerałów.

1.1.2 Struktura pliku i organizacja arkuszy

Dane są zebrane w pliku Excel. Skoroszyt ma strukturę:

- jednego arkusza głównego *Master* (zawiera wszystkie informacje, unikatowy klucz dla każdego badania oraz ewentualny komentarz),
- wielu arkuszy pomocniczych z objaśnieniami skrótów i kodów.

Uwaga: skróty i odwołania w arkuszu Master

W arkuszu Master użyto skrótów/hasel w celu ograniczenia rozmiaru tabeli (np. *GestAge(week)*, *Age_m(year)* czy odwołania typu $\$LAC(g/L) = Arnold87full_LAC$). Objasnienia znajdują się w arkuszach pomocniczych pogrupowanych zgodnie z kolumną, której dotyczą (np. Condition, Meas Method).

1.2 Potencjalne problemy i ograniczenia analizy

Jakie problemy możemy napotkać?

- Duży rozmiar bazy: nawigacja, filtrowanie i odnajdywanie informacji może być utrudnione, co zwiększa ryzyko pominięcia istotnych rekordów.
- Trudność w porównywaniu badań: różne metody pomiarowe implikują inne analizowane właściwości. Przy testowaniu zależności może się okazać, że interesujący składnik był mierzony zbyt rzadko, aby uzyskać wystarczającą moc wnioskowania.
- Trudności interpretacyjne: brak intuicji chemicznej może wydłużać interpretację wyników. Skład mleka obejmuje wiele związków chemicznych, co może utrudniać zrozumienie ich roli i wpływu.

[illegible]

Rysunek 1: Wygląd oryginalnej bazy

1.3 Wstępna obróbka i deagregacja danych

Wstępna analiza bazy danych MilkyBase [15, 16] wykazała, że jej struktura jest trudna do bezpośredniego opracowania, ponieważ w kolumnach *Condition* oraz *Component* dane z poszczególnych badań zostały zagregowane wewnątrz pojedynczych komórek.

Przykład:

$Calcitriol_mol(mol/L) = !Ala_ForeWinCalcitriol_25VitD2_Suppl/VitD3_mol(mol/L) = !Ala_ForeWinVitD3_25VitD2_Suppl$

Taka konstrukcja informacji pozwoliła na wykorzystanie programu SAS do deagregacji danych. Proces ten polegał na rozdzieleniu zawartości kolumn *Component* oraz *Condition* w taki sposób, aby nazwami nowych kolumn stały się frazy pojawiające się przed znakiem „=”. W rezultacie uzyskano zbiór składający się z 895 wierszy i 727 kolumn.

VitC_mol_mol_L_1	Zn_mol_mol_L_1	Prot_g_L_1	Calcitriol_mol_mol_L_1	VitD3_mol_mol_L_1
		14		
		!John_018_Prot		
		!John_019_Prot		
		9.6		
		!John_021_Prot		
		!John_022_Prot		
		!John_023_Prot		
		!John_024_Prot		
		8.9		
		!John_026_Prot		
		!John_027_Prot		
		!John_028_Prot		
		!John_029_Prot		
		10.5		
		!John_031_Prot		
		10.2		
		9.6		
		12.1		
		14.1		
		10.1		
		8.8		
		!John_038_Prot		
		!John_039_Prot		
		!John_040_Prot		
		9		
		13		
		!John_043_Prot		
		8.6		
		!John_045_Prot		
		9.9		
		8		
		!John_048_Prot		
		12.5		
		9.2		
		1.2		

Rysunek 2: Wygląd bazy po deagregacji kolumn

1.4 Analiza kompletności danych

Podczas analizowania nowej bazy zaobserwowano znaczną liczbę pustych komórek. Skłoniło to nas do sprawdzenia, ile danych zawiera każda z kolumn powstałych pierwotnie z kolumny *Component*. Wyniki tej weryfikacji pokazały, że zaledwie 3 z 665 takich kolumn posiadały więcej niż 100 wpisów, natomiast aż 529 zawierało mniej niż 10 obserwacji. Tak duża liczba braków danych sprawia, że większość kolumn ma bardzo ograniczoną przydatność w kontekście analizy statystycznej.

Zmienna	N	Zmienna	N	Zmienna	N	Zmienna	N
Prot_g_L__1	584	C16_1n_7_FAc__1	33	SerA_g_L__1	20	VitB2_g_L__1	14
Fat_g_L__1	573	C16_1_FAc__1	31	ThrA_g_L__1	20	MFMSLNH1_g_L__1	13
LAC_g_L__1	490	C22_0_FAc__1	29	TyrA_g_L__1	20	ValA_g_L__1	20
C18_3n_3_FAc__1	79	C22_4n_6_FAc__1	29	2FL_g_L__1	19	LNFP1_g_L__1	19
Zn_g_L__1	77	C22_1n_9_FAc__1	27	C18_2n_6_g_L__1	19	CysA_g_L__1	19
CH_g_L__1	76	C14_1_FAc__1	26	C22_2n_6_FAc__1	19	3FL_g_L__1	18
Ca_g_L__1	75	C17_1_FAc__1	23	LNT_g_L__1	18	C20_4n_6_g_L__1	18
C20_4n_6_FAc__1	73	C20_3n_3_FAc__1	23	GAG_g_L__1	18	C18_1n_7_FAc__1	18
C14_0_FAc__1	72	AlphaTocoph_g_L__1	23	C14_1n_5_FAc__1	18	IgA_g_L__1	17
C16_0_FAc__1	72	3SL_g_L__1	22	neo_LNT_g_L__1	17	LSTa_g_L__1	17
C18_0_FAc__1	72	6SL_g_L__1	22	Se_g_L__1	17	C13_0_FAc__1	17
C22_6n_3_FAc__1	72	DSLNT_g_L__1	22	LSTb_g_L__1	21	LSTc_g_L__1	21
Cu_g_L__1	71	Mg_g_L__1	21	Fe_g_L__1	21	C22_5n_6_FAc__1	21
P_g_L__1	69	C18_3n_3_g_L__1	20	C22_6n_3_g_L__1	20	C18_1_FAc__1	20
C18_2n_6_FAc__1	69	C12_0_FAc__1	65	C20_5n_3_FAc__1	65	K_g_L__1	64
C10_0_FAc__1	62	C20_3n_6_FAc__1	60	MSMFLNH_g_L__1	13	DSMFLNH_g_L__1	13
C18_0_g_L__1	13	C20_0_g_L__1	13	C18_1t_FAc__1	13	C24_1n_9_FAc__1	13
C16_1n_9_FAc__1	13	Na_mol_mol_L__1	12	C17_1n_7_FAc__1	12	Mn_g_L__1	12
VitA_mol_mol_L__1	11	Calcitriol_mol_mol_L__1	11	VitD3_mol_mol_L__1	11	C16_0_g_L__1	11
C16_1n_7_g_L__1	11	C18_1n_9_g_L__1	11	C20_5n_3_g_L__1	11	C24_0_g_L__1	11

Tabela 1: Pozostałe zmienne z liczbą obserwacji < 10 (łącznie): 529

1.5 Wybór ostatecznego zbioru badawczego

Dodatkowym utrudnieniem był fakt, że w wielu komórkach zamiast wartości liczbowych pojawiały się odwołania tekstowe, na przykład *!John_026_Prot*. Taka treść komórki informowała, że dla danej pacjentki badany składnik mierzono wielokrotnie wraz z upływem czasu, a konkretne wyniki znajdują się w innym arkuszu pliku Excel. Taki sposób przedstawienia danych uniemożliwiał skuteczną analizę bez czasochłonnego łączenia wielu zbiorów.

Ostatecznie naszą uwagę przykuły trzy kolumny z największą liczbą danych: *Prot_g_L__1*, *Fat_g_L__1* oraz *LAC_g_L__1*. Jak ustalono, zdecydowana większość informacji w tych kolumnach pochodzi z jednego opracowania o tytule **Macronutrient variability in human milk from donors to a milk bank: Implications for feeding preterm infants** [2]. W efekcie, po konsultacjach z opiekunką projektu, podjęto decyzję o zawężeniu analizy wyłącznie do danych pochodzących z badań opisanych we wspomnianym artykule. Takie rozwiązanie uznano za bardziej efektywne i wartościowe pod względem poznawczym.

2 Charakterystyka analizowanego zbioru danych

2.1 Pochodzenie danych

Zgodnie z wnioskami płynącymi z analizy wstępnej, właściwa część projektu opiera się wyłącznie na danych wyselekcjonowanych z artykułu pt. *Macronutrient variability in human milk from donors to a milk bank: Implications for feeding preterm infants*, opublikowanego w czasopiśmie naukowym *PLOS ONE* [2].

Oryginalne badanie, z którego pochodzą dane, koncentrowało się na ocenie zmienności podstawowych makroskładników w mleku kobiecym przekazywanym przez dawczynie do banków mleka. Analiza ta miała na celu lepsze zrozumienie wartości odżywczej mleka w kontekście żywienia wcześniaków. Zbiór ten okazał się najbardziej kompletnym i rzetelnym fragmentem wyjściowej bazy MilkyBase.

2.2 Opis badanych zmiennych

W celu realizacji naszych hipotez badawczych z wyselekcjonowanego zbioru wyodrębniono kluczowe parametry ilościowe oraz katagoryczne. Zmienne te można podzielić na dwie główne grupy:

1. Zmienne objaśniane (Skład chemiczny mleka):

- **Białko** (*Prot_g_L__1*): stężenie białka w mleku, wyrażone w gramach na litr (g/L).
- **Tłuszcz** (*Fat_g_L__1*): stężenie tłuszczu w mleku, wyrażone w gramach na litr (g/L).
- **Laktoza** (*LAC_g_L__1*): stężenie laktozy w mleku, wyrażone w gramach na litr (g/L).

2. Zmienne objaśniające i metadane:

- **Wiek matki**: zmienna katagoryczna dzieląca dawczynie na dwie grupy wiekowe: kobiety młodsze (poniżej 30 lat) oraz kobiety starsze (30 lat i więcej).
- **Term (Dojrzałość i wynik porodu)**: zmienna katagoryczna określająca status noworodka w momencie rozwiązania. W analizowanym zbiorze przyjmuje ona trzy

wartości: *term* (ciąża donoszona, dziecko urodzone w terminie), *preterm* (poród przedwczesny, wcześniak) oraz *deceased* (przypadek zgonu dziecka lub poronienia). Zmienna ta ma kluczowe znaczenie, ponieważ skład mleka może znacząco różnić się w zależności od czasu trwania i finału ciąży.

- **Wiek mleka (*Age of Milk [Days Since Birth]*):** zmienna ciągła określająca czas (w dniach), jaki upłynął od momentu porodu do dnia odciągnięcia danej próbki mleka.
- **Kolejność pobrania (*Subject_Deposit_Order*):** zmienna porządkowa pełniąca rolę identyfikatora. Wskazuje ona, która to z kolei próbka oddana do banku przez tę samą kobietę.

2.3 Struktura próby badawczej

Specyfika pozyskiwania danych do banków mleka sprawia, że w bazie znajdowało się wiele pomiarów pochodzących od tych samych pacjentek (wielokrotne oddawanie próbek z upływem czasu). Stanowiło to problem w kontekście założeń niektórych testów statystycznych, które wymagają absolutnej niezależności obserwacji.

Z tego powodu podjęto decyzję o operowaniu na dwóch wariantach zbioru danych w zależności od użytego narzędzia statystycznego:

1. **Zbiór prób niezależnych ($n = 442$):** Utworzony poprzez przefiltrowanie bazy wyłącznie do pierwszego pobrania mleka od każdej z matek (*Subject_Deposit_Order* = 1). Ten zbiór posłużył do weryfikacji hipotez, w których każda kobieta mogła być reprezentowana tylko raz (np. przy testach różnicowania ze względu na wiek matki czy początkowych testach normalności rozkładu).
2. **Pełny zbiór danych:** Uwzględniający wszystkie zarejestrowane pomiary, w tym wielokrotne pobrania od tych samych kobiet. Zbiór ten wykorzystano do poszukiwania ogólnych trendów oraz analizy wpływu wieku mleka na jego skład, gdzie powtarzalność pomiarów w czasie stanowiła wartość dodaną dla modelu.

3 Podstawy teoretyczne

3.1 Analiza rozkładu danych

Weryfikacja normalności rozkładu jest kluczowym etapem analizy, determinującym wybór między metodami parametrycznymi a nieparametrycznymi [1]. Stosuje się tu układ hipotez, gdzie hipoteza zerowa (H_0) zakłada zgodność rozkładu cechy z rozkładem normalnym, a hipoteza alternatywna (H_1) stwierdza brak takiej zgodności.

3.1.1 Test Shapiro-Wilka

Statystyka testowa W opiera się na analizie wariancji i obliczana jest według wzoru [3]:

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

gdzie $x_{(i)}$ to statystyki pozycyjne, $\bar{x}$ to średnia z próby, a a_i to stałe tablicowe. Wartość statystyki W mieści się w przedziale $(0, 1]$. Im bliższa jedności jest wartość W , tym bardziej rozkład próby przypomina rozkład normalny. Decyzję podejmuje się na podstawie wartości p (p-value). Jeśli $p < \alpha$ (gdzie α to przyjęty poziom istotności, np. 0,05), odrzucamy hipotezę zerową na rzecz alternatywnej, co oznacza, że rozkład badanej cechy istotnie odbiega od normalnego. Jeśli $p \geq \alpha$, nie ma podstaw do odrzucenia H_0 .

3.1.2 Test Kołmogorowa-Smirnowa

Test ten opiera się na porównaniu dystrybuanty empirycznej badanej próby $F_n(x)$ z dystrybuantą teoretyczną rozkładu normalnego $F_0(x)$. Statystyka testowa D_n określa maksymalną bezwzględną różnicę między nimi [3]:

$$D_n = \sup_x |F_n(x) - F_0(x)|$$

Większa odległość między dystrybuantami (duża wartość D_n) świadczy o gorszym dopasowaniu do rozkładu normalnego. Podobnie jak w teście Shapiro-Wilka, wnioskowanie opiera się na wartości p . Jeśli obliczona wartość p jest mniejsza od ustalonego poziomu istotności α , hipotezę o normalności rozkładu odrzucamy.

3.2 Test istotności dla różnicy dwóch średnich

Test ten służy do weryfikacji hipotezy, czy dwie niezależne populacje różnią się pod względem wartości średniej badanej cechy.

Hipoteza zerowa ($H_0 : \mu_1 = \mu_2$) zakłada brak różnic między średnimi, natomiast hipoteza alternatywna ($H_1 : \mu_1 \neq \mu_2$) zakłada, że średnie różnią się w sposób statystycznie istotny.

W przypadku dużych prób statystykę testową U (często oznaczaną również jako Z) wyznacza się ze wzoru [4]:

$$U = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

gdzie $\bar{x}_1, \bar{x}_2$ to średnie z prób, s_1, s_2 to odchylenia standardowe, a n_1, n_2 to liczebności porównywanych grup. Statystyka ta pozwala ocenić, o ile błędów standardowych różnią się od siebie średnie.

Istotność różnicy ocenia się, porównując wyliczoną wartość z wartością krytyczną odczytaną z tablic rozkładu normalnego (dla $\alpha = 0,05$ wartość krytyczna wynosi w przybliżeniu $\pm 1,96$) lub analizując wartość p .

Jeżeli wartość bezwzględna statystyki testowej znajdzie się w obszarze krytycznym (lub $p < \alpha$), hipotezę zerową odrzucamy, co oznacza, że różnica między grupami jest statystycznie istotna.

Jeśli statystyka nie wpadnie do obszaru krytycznego (lub $p \geq \alpha$), przyjmujemy, że nie ma wystarczających dowodów na istnienie różnicy.

3.3 Współczynnik korelacji rang Spearmana

Współczynnik korelacji rang Spearmana jest nieparametryczną metodą oceny zależności pomiędzy zmiennymi. Metoda ta opiera się na rangach obserwacji, dzięki czemu jest mniej wrażliwa na obserwacje odstające oraz może być stosowana dla danych niespełniających założenia normalności rozkładu.

Współczynnik korelacji Spearmana definiuje się następująco [5]:

$$r_s = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

gdzie:

- d_i – różnica między rangami odpowiadających sobie wartości cech x_i i y_i ,
- n – liczba par obserwacji.

Wartość współczynnika r_s należy do przedziału $[-1, 1]$. Dodatnie wartości wskazują na zależność rosnącą, ujemne na malejącą, natomiast wartości bliskie zeru oznaczają brak wyraźnej zależności.

W celu oceny istotności statystycznej wykorzystuje się statystykę testową [5]:

$$t = \frac{r_s \sqrt{n-2}}{\sqrt{1-r_s^2}}$$

która dla dużych prób ma w przybliżeniu rozkład t-Studenta z $n - 2$ stopniami swobody.

Istotność statystyczną ocenia się na podstawie wartości (p-value), czyli prawdopodobieństwa uzyskania obserwowanego wyniku przy założeniu prawdziwości hipotezy zerowej. Jeśli $p < \alpha$, odrzuca się hipotezę zerową o braku zależności. Przykładowe zastosowania:

1. **Analiza danych medycznych:** Może być używany do badania zależności między różnymi czynnikami a zdrowiem pacjentów. Na przykład, możemy użyć tego współczynnika do oceny związku między paleniem papierosów a ryzykiem zachorowania na raka płuc. [6]
2. **Analiza danych niskiej jakości:** w przypadku danych zawierających błędy pomiarowe lub brakujące wartości. Na przykład, jeśli prowadzimy badania ankietowe, gdzie respondenci mogą nieodpowiedzieć na niektóre pytania, możemy użyć tego współczynnika do identyfikacji zależności między zmiennymi, pomijając brakujące wartości. [6]

3.4 Regresja liniowa

Regresja liniowa to metoda modelowania statystycznego, która bada związek między zmiennymi i pozwala przewidywać wartości jednej zmiennej na podstawie drugiej.

Model regresji ma postać [7]:

$$y = \beta_0 + \beta_1 x + \varepsilon$$

gdzie:

- β_0 – wyraz wolny (wartość y dla $x = 0$),
- β_1 – współczynnik kierunkowy (zmiana y przy jednostkowej zmianie x),
- ε – składnik losowy.

Parametry modelu wyznacza się metodą najmniejszych kwadratów. Współczynnik kierunkowy oblicza się ze wzoru:

$$\beta_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

a wyraz wolny jako:

$$\beta_0 = \bar{y} - \beta_1 \bar{x}$$

Interpretacja współczynnika kierunkowego:

- $\beta_1 > 0$ oznacza wzrost wartości y wraz ze wzrostem x ,
- $\beta_1 < 0$ oznacza spadek wartości y wraz ze wzrostem x .

Stopień dopasowania modelu opisuje współczynnik determinacji [7]:

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}}$$

gdzie:

- $SS_{\text{res}} = \sum (y_i - \hat{y}_i)^2$ – suma kwadratów reszt,
- $SS_{\text{tot}} = \sum (y_i - \bar{y})^2$ – całkowita zmienność danych.

Wartość R^2 należy do przedziału $[0, 1]$ i określa, jaka część zmienności zmiennej zależnej jest wyjaśniana przez model regresji.

3.5 Metoda wygładzania LOESS

Metoda LOESS jest metodą regresji lokalnej stosowaną do wygładzania danych i pokazania ich ogólnego trendu, co ułatwia późniejsze dopasowanie odpowiedniej funkcji. Dla każdego punktu x metoda analizuje jego najbliższe otoczenie i dopasowuje lokalny model regresji, przy czym punkty położone bliżej mają większy wpływ na wynik niż punkty bardziej oddalone.

Dla danego punktu x wagi obserwacji można zapisać jako [8]

$$w_i(x) = W\left(\frac{x_i - x}{h}\right),$$

gdzie h oznacza szerokość pasma, czyli parametr określający wielkość lokalnego otoczenia, a $W(\cdot)$ jest funkcją wag.

Lokalny model regresji można zapisać w postaci

$$\mu(x_i) \approx \beta_0 + \beta_1(x_i - x) + \cdots + \beta_p(x_i - x)^p,$$

gdzie p oznacza stopień lokalnego wielomianu.

Współczynniki modelu wyznacza się metodą ważonych najmniejszych kwadratów poprzez minimalizację funkcji

$$\sum_{i=1}^n w_i(x) (Y_i - \beta_0 - \beta_1(x_i - x) - \cdots - \beta_p(x_i - x)^p)^2.$$

Oszacowana wartość funkcji regresji w punkcie x jest równa

$$\hat{\mu}(x) = \hat{\beta}_0.$$

Często stosowaną funkcją wag jest funkcja tricube:

$$W(u) = (1 - |u|^3)^3 \quad \text{dla } |u| < 1.$$

Dla kolejnych punktów ponownie wyznaczane są wagi i dopasowywany jest lokalny model regresji. Połączenie uzyskanych lokalnych dopasowań tworzy wygładzoną krzywą LOESS.

3.6 Metryki służące do oceny jakości modeli

3.6.1 RMSE (ang. *Root Mean Squared Error*)

Jest to pierwiastek z błędu średniokwadratowego, który służy do mierzenia wielkości błędu modelu, czyli średniej odległości między jego prognozami a rzeczywistymi wartościami.

Przyjmuje on wartości z zakresu $[0, \infty)$, gdzie najkorzystniejsze są te bliskie zeru, a wyrażany jest wzorem [9]:

$$\text{RMSE} = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

3.6.2 R^2 (współczynnik determinacji)

Jest to miernik dopasowania modelu, który określa, jaka część całkowitej zmienności (wariancji) danych testowych została wyjaśniona przez model.

Przyjmuje wartości z zakresu $[0, 1]$, przy czym wynik bliższy jedności świadczy o dokładniejszym dopasowaniu funkcji regresji do danych empirycznych. Opiera się na stosunku sumy kwadratów reszt (SS_{res}) do całkowitej sumy kwadratów (SS_{tot}) i wyraża się wzorem [10]:

$$R^2 = 1 - \frac{SS_{\text{res}}}{SS_{\text{tot}}} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

W przypadku rozważanym w rozdziale 4.6 obliczenia były wykonane zgodnie z poniższymi oznaczeniami:

- y_i – rzeczywista (prawdziwa) wartość zmiennej **Protein** dla i -tego rekordu w zbiorze testowym,
- $\hat{y}_i$ – wartość **Protein** prognozowana (przewidziana) przez dany model wielomianowy,
- $\bar{y}$ – średnia arytmetyczna z rzeczywistych wartości **Protein** w zbiorze testowym,
- n – liczba rekordów (obserwacji) w zbiorze testowym.

Aby wybrać model o jak najlepszym dopasowaniu, sugerujemy się jak najmniejszym RMSE oraz R^2 jak najbliższym 1. Jeśli natomiast otrzymamy R^2 mniejsze niż 0, oznacza to, że model gorzej opisuje badaną zależność niż prosta średnia arytmetyczna wartości rzeczywistych.

3.7 Test Kruskala-Wallisa

Test Kruskala-Wallisa jest nieparametrycznym testem statystycznym, który służy do porównywania median więcej niż dwóch grup. Jest to rozszerzenie testu Manna-Whitneya i alternatywa dla jednoczynnikowej analizy wariancji (ANOVA), gdy założenia o normalności danych nie są spełnione.

Test Kruskala-Wallisa jest nieparametrycznym narzędziem statystycznym służącym do porównywania median w trzech lub więcej niezależnych grupach.

Wzór na test Kruskala-Wallisa ma postać [11]:

$$H = \frac{12}{N(N+1)} \sum_{i=1}^p \frac{R_i^2}{n_i} - 3(N+1)$$

gdzie:

- N – liczba wszystkich obserwacji,
- p – liczba porównywanych grup,
- R_i – suma rang w danej grupie,
- n_i – liczba obserwacji w danej grupie,

Dla dużych prób statystyka H ma w przybliżeniu rozkład chi-kwadrat:

$$H \sim \chi_{k-1}^2$$

gdzie

$$df = k - 1$$

oznacza liczbę stopni swobody testu. Istotność statystyczną ocenia się na podstawie wartości p wyznaczonej z rozkładu chi-kwadrat.

Jeśli $p < \alpha$, odrzuca się hipotezę zerową, co oznacza, że istnieją istotne różnice między grupami.

3.8 Test Dunna z korektą Bonferroniego

Test Dunna jest nieparametrycznym testem post-hoc stosowanym po odrzuceniu hipotezy zerowej w teście Kruskala-Wallisa. Polega on na obliczeniu różnic między średnimi rangami grup, uwzględniając poprawkę na rangi wiązane oraz wybraną metodę korekty istotności.

3.8.1 Statystyka testowa Z

Dla każdej pary porównywanych grup obliczana jest statystyka Z według wzoru [12]:

$$Z = \frac{\sum_{j=1}^k c_j \bar{R}_j}{\sqrt{\left(\frac{N(N+1)}{12} - \frac{\sum(t^3-t)}{12(N-1)}\right) \sum_{j=1}^k \frac{c_j^2}{n_j}}}$$

gdzie:

- k – liczba porównywanych grup badawczych;
- c_j – współczynnik kontrastu dla j -tej grupy. W porównaniach parowych przyjmuje on wartość 1 dla pierwszej grupy, -1 dla drugiej oraz 0 dla grup niebiorących udziału w danym porównaniu;
- $\bar{R}_j$ – średnia rang przypisanych obserwacjom w j -tej grupie;
- N – całkowita liczebność próby (suma obserwacji we wszystkich grupach);
- n_j – liczebność j -tej grupy badawczej;
- t – liczba obserwacji o tej samej wartości zmiennej.

3.8.2 Korekta Bonferroniego

Następnie surowe wartości p (p_{unadj}) są modyfikowane, aby uniknąć błędu I rodzaju wynikającego z wielokrotnego testowania. Procedura przebiega następująco:

1. Wyznaczana jest liczba wszystkich wykonanych porównań prostych k .
2. Skorygowana wartość p (p_{adj}) jest obliczana jako iloczyn surowej wartości p i liczby porównań:

$$p_{adj} = p_{unadj} \cdot k$$

Wynik uznaje się za istotny statystycznie, jeżeli skorygowana wartość p_{adj} jest mniejsza od założonego poziomu istotności.

4 Wyniki

4.1 Analiza normalności rozkładu badanych makroskładników w mleku kobiecym

W celu weryfikacji hipotezy o normalności rozkładu, analizę przeprowadzono w dwóch wariantach: dla zbioru ograniczonego do pierwszego pobrania (próby niezależne) oraz dla pełnego zbioru danych uwzględniającego wszystkie zarejestrowane pomiary.

4.1.1 Część I: Analiza dla prób niezależnych $n = 442$

Poniższe zestawienie dotyczy zbioru danych przefiltrowanego do pierwszego pobrania dla każdej pacjentki (*Subject_Deposit_Order* = 1). Jest to kluczowa analiza z punktu widzenia testów istotności wymagających niezależności obserwacji.

Zmienna	Shapiro-Wilk		Kolmogorow-Smirnow	
	Stat. W	Wartość p	Stat. D	Wartość p
Białko (Protein)	0,9488	$p < 0,0001$	0,1005	$p < 0,0100$
Tłuszcz (Fat)	0,9863	$p = 0,0003$	0,0606	$p < 0,0100$
Laktoza (Lactose)	0,9489	$p < 0,0001$	0,1025	$p < 0,0100$

Tabela 2: Wyniki testów normalności dla pierwszego pobrania ($n = 442$)

4.1.2 Oryginalne zdjęcia z systemu SAS

Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.948785	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.100522	Pr > D	<0.0100

Rysunek 3: Testy normalności dla zmiennej Białko (Pierwsze pobranie)


Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.986253	Pr < W	0.0003
Kolmogorov-Smirnov	D	0.060574	Pr > D	<0.0100

Rysunek 4: Testy normalności dla zmiennej Tłuszcz (Pierwsze pobranie)


Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.948934	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.102531	Pr > D	<0.0100

Rysunek 5: Testy normalności dla zmiennej Laktoza (Pierwsze pobranie)


4.1.3 Analiza Wizualna



Rysunek 6: Rozkład Białka ($n = 442$) – widoczna asymetria prawostronna



Rysunek 7: Rozkład Tłuszczu ($n = 442$)



Rysunek 8: Rozkład Laktozy ($n = 442$) – silna kurtoza dodatnia

4.1.4 Wnioski szczegółowe dla prób niezależnych

- **Białko (Protein):** Zarówno w teście Shapiro-Wilka ($p < 0,0001$), jak i Kołmogorowa-Smirnowa ($p < 0,0100$) uzyskane wartości p są znacznie niższe od założonego poziomu istotności $\alpha = 0,05$. W związku z tym **odrzucaamy hipotezę zerową** na rzecz alternatywnej – rozkład białka nie jest normalny. Analiza histogramu potwierdza to rozstrzygnięcie, wykazując wyraźną asymetrię prawostronną (większość próbek ma niską zawartość białka, przy obecności nielicznych wyników bardzo wysokich).
- **Tłuszcz (Fat):** Wyniki obu testów ($p = 0,0003$ dla S-W oraz $p < 0,0100$ dla K-S) są mniejsze niż $\alpha = 0,05$. Stanowi to podstawę do **odrzućcenia hipotezy zerowej**. Wizualizacja rozkładu wskazuje na obecność charakterystycznego prawego „ogona”, co oznacza, że mimo pozornego podobieństwa do krzywej Gaussa, dane zawierają zbyt dużą liczbę obserwacji o wysokiej zawartości tłuszczu, by uznać rozkład za normalny.
- **Laktoza (Lactose):** Skrajnie niskie wartości p w obu testach ($p < 0,0001$ oraz $p < 0,0100$) wymuszają **odrzućcenie hipotezy zerowej** o normalności rozkładu. Na histogramie widoczna jest silna kurtoza dodatnia – dane są bardzo mocno skoncentrowane w wąskim przedziale wokół średniej.

4.1.5 Część II: Analiza porównawcza dla pełnego zbioru danych

W celu oceny ogólnej charakterystyki materiału biologicznego przeprowadzono analizę dla wszystkich dostępnych próbek. W tym wariancie liczebność próby znacząco wzrasta, co zwiększa moc testów w wykrywaniu odchyłań od modelu teoretycznego.

Zmienna	Shapiro-Wilk		Kołmogorow-Smirnow	
	Stat. W	Wartość p	Stat. D	Wartość p
Białko (Protein)	0,9541	$p < 0,0001$	0,0873	$p < 0,0100$
Tłuszcz (Fat)	0,9803	$p < 0,0001$	0,0656	$p < 0,0100$
Laktoza (Lactose)	0,9439	$p < 0,0001$	0,0955	$p < 0,0100$

Tabela 3: Wyniki testów normalności dla pełnego zbioru danych (wszystkie obserwacje)

4.1.6 Oryginalne zdjęcia z systemu SAS (Pełny zbiór)

Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.954065	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.087283	Pr > D	<0.0100

Rysunek 9: Testy normalności dla zmiennej Białko (Wszystkie obserwacje)


Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.980303	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.065634	Pr > D	<0.0100

Rysunek 10: Testy normalności dla zmiennej Tłuszcz (Wszystkie obserwacje)


Tests for Normality				
Test	Statistic		p Value	
Shapiro-Wilk	W	0.943941	Pr < W	<0.0001
Kolmogorov-Smirnov	D	0.095489	Pr > D	<0.0100

Rysunek 11: Testy normalności dla zmiennej Laktoza (Wszystkie obserwacje)


4.1.7 Analiza Wizualna (Pełny zbiór):



Rysunek 12: Histogram rozkładu Białka dla pełnego zbioru danych



Rysunek 13: Histogram rozkładu Tłuszczu dla pełnego zbioru danych



Rysunek 14: Histogram rozkładu Laktozy dla pełnego zbioru danych

4.1.8 Wniosek:

Zwiększenie liczebności próby doprowadziło do jeszcze silniejszego odrzucenia hipotezy o normalności rozkładu ($p < 0,0001$ dla wszystkich makroskładników). Potwierdza to, że nienormalność nie wynika z doboru próby, lecz jest stałą cechą biologiczną badanych parametrów.

4.2 Analiza składników mleka matki w zależności od wieku matki

Celem niniejszej analizy było sprawdzenie, czy wiek matki wpływa na podstawowy skład makroskładników w mleku. Weryfikację przeprowadzono dla białka, laktozy i tłuszczu, przyjmując hipotezę zerową (H_0) o równości średnich w populacjach oraz hipotezę alternatywną (H_1) o występowaniu istotnej statystycznie różnicy.

Aby zbadać tę zależność, analizę statystyczną przeprowadzono w dwóch wariantach: z podziałem szerokim (< 30 vs ≥ 30 lat) oraz z podziałem skrajnym (≤ 25 vs ≥ 35 lat).

4.2.1 Wariant I: Podział szeroki (Matki młodsze < 30 lat vs starsze ≥ 30 lat)

Badane kobiety podzielono na dwie grupy: grupę młodszych matek (poniżej 30 lat, $n_1 = 161$) oraz grupę starszych matek (30 lat i więcej, $n_2 = 281$).

Poniższa tabela przedstawia parametry uzyskane z systemu SAS, które posłużyły do wyznaczenia statystyk testowych.

Wiek	N obs.	Zmienna	N	Średnia ($\bar{x}$)	Odch. std. (s)
< 30	161	Białko	161	1,1065	0,2273
		Laktoza	161	7,2247	0,2436
		Tłuszcz	161	3,5141	0,8738
≥ 30	281	Białko	281	1,1363	0,2228
		Laktoza	281	7,2014	0,2248
		Tłuszcz	281	3,5654	0,8068

Tabela 4: Statystyki opisowe makroskładników w szerokich grupach wiekowych

Z uwagi na duże liczebności prób, do weryfikacji hipotez wykorzystano statystykę U . Obliczenia przeprowadzono według wzoru na różnicę dwóch średnich:

$$U = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

1. Analiza zawartości białka (Protein):

$$U_{Protein} = \frac{1,1065 - 1,1363}{\sqrt{\frac{0,2273^2}{161} + \frac{0,2228^2}{281}}} \approx -1,339$$

2. Analiza zawartości laktozy (Lactose):

$$U_{Lactose} = \frac{7,2247 - 7,2014}{\sqrt{\frac{0,2436^2}{161} + \frac{0,2248^2}{281}}} \approx 0,994$$

3. Analiza zawartości tłuszczu (Fat):

$$U_{Fat} = \frac{3,5141 - 3,5654}{\sqrt{\frac{0,8738^2}{161} + \frac{0,8068^2}{281}}} \approx -0,611$$

Przyjmując standardowy poziom istotności $\alpha = 0,05$, wartość krytyczna wynosi około $\pm 1,96$. Ponieważ dla każdej z badanych zmiennych (Białko: $U \approx -1,339$, Laktoza: $U \approx 0,994$, Tłuszcz: $U \approx -0,611$) otrzymana wartość statystyki testowej nie mieści się w obszarze krytycznym, **nie ma podstaw do odrzucenia hipotezy zerowej**. Oznacza to, że nie wykazano statystycznie istotnych różnic w składzie makroskładników mleka między młodszymi a starszymi matkami przy tym podziale.

4.2.2 Wariant II: Podział skrajny (Matki najmłodsze ≤ 25 lat vs najstarsze ≥ 35 lat)

W celu sprawdzenia, czy różnice ujawnią się przy porównaniu bardziej odległych grup wiekowych, z podzbioru prób niezależnych wyodrębniono kobiety bardzo młode (≤ 25 lat, $n_1 = 50$) oraz kobiety dojrzałe (≥ 35 lat, $n_2 = 75$). Obserwacje dla kobiet w przedziale wieku 26–34 lata zostały celowo usunięte z tej części analizy.

Poniższa tabela przedstawia statystyki opisowe dla nowo wyznaczonych, skrajnych grup wiekowych uzyskane z programu SAS.

Wiek	N obs.	Zmienna	N	Średnia ($\bar{x}$)	Odch. std. (s)
≤ 25	50	Białko	50	1,0430	0,1701
		Laktoza	50	7,2550	0,2904
		Tłuszcz	50	3,4608	0,8832
≥ 35	75	Białko	75	1,1229	0,2090
		Laktoza	75	7,2195	0,2390
		Tłuszcz	75	3,3963	0,6525

Tabela 5: Statystyki opisowe makroskładników w skrajnych grupach wiekowych

Podobnie jak w poprzednim wariancie, do weryfikacji hipotez wykorzystano statystykę U . Obliczenia przeprowadzono według wzoru na różnicę dwóch średnich:

1. Analiza zawartości białka (Protein):

$$U_{Protein} = \frac{1,0430 - 1,1229}{\sqrt{\frac{0,1701^2}{50} + \frac{0,2090^2}{75}}} \approx -2,35$$

2. Analiza zawartości laktozy (Lactose):

$$U_{Lactose} = \frac{7,2550 - 7,2195}{\sqrt{\frac{0,2904^2}{50} + \frac{0,2390^2}{75}}} \approx 0,72$$

3. Analiza zawartości tłuszczu (Fat):

$$U_{Fat} = \frac{3,4608 - 3,3963}{\sqrt{\frac{0,8832^2}{50} + \frac{0,6525^2}{75}}} \approx 0,44$$

Przyjęto standardowy poziom istotności $\alpha = 0,05$, dla którego wartość krytyczna wynosi około $\pm 1,96$. W przypadku laktozy ($U \approx 0,72$) oraz tłuszczu ($U \approx 0,44$), otrzymana wartość statystyki testowej nie mieści się w obszarze krytycznym, co oznacza brak podstaw do odrzucenia hipotezy zerowej.

Inny rezultat uzyskano w przypadku białka. Obliczona wartość statystyki $U \approx -2,35$ wpadła do lewostronnego obszaru krytycznego $(-\infty, -1,96]$. Stanowi to podstawę do **odrzucenia hipotezy zerowej** na rzecz hipotezy alternatywnej (co potwierdza również empiryczna wartość $p = 0,02$ uzyskana z programu SAS).

Porównanie skrajnych grup wiekowych wykazało, że o ile zawartość laktozy i tłuszczu pozostaje stabilna, o tyle zawartość białka jest istotnie statystycznie wyższa w mleku matek dojrziałych (≥ 35 lat) w porównaniu do matek bardzo młodych (≤ 25 lat).

4.3 Analiza współzależności makroskładników

W celu zbadania siły i kierunku związków między głównymi składnikami mleka kobiecego, wyznaczono macierz korelacji rang Spearmana. Wybór tego współczynnika był podyktowany stwierdzonym wcześniej brakiem normalności rozkładów oraz odpornością metody na wartości odstające.

4.3.1 Wyniki analizy korelacji

Poniższa tabela prezentuje współczynniki korelacji r_s i odpowiadające im wartości p , obliczone dla głównych składników odżywczych w podzbiorze prób niezależnych ($n = 442$).

Zmienna	Białko (Protein)	Tłuszcz (Fat)	Laktoza (Lactose)
Białko	1,00000	0,25186 ($p < 0,0001$)	0,03261 ($p = 0,4940$)
Tłuszcz	0,25186 ($p < 0,0001$)	1,00000	-0,10447 ($p = 0,0281$)
Laktoza	0,03261 ($p = 0,4940$)	-0,10447 ($p = 0,0281$)	1,00000

Tabela 6: Macierz korelacji rang Spearmana dla makroskładników

4.3.2 Interpretacja i wnioski statystyczne

Na podstawie uzyskanych wyników, przy założonym poziomie istotności $\alpha = 0,05$, sformułowano następujące wnioski:

- **Białko vs Tłuszcz:** Odnotowano współczynnik $r_s \approx 0,25$ przy $p < 0,0001$. Ponieważ $p < \alpha$, zależność ta jest **statystycznie istotna**. Dodatni znak współczynnika wskazuje na słabą korelację wprost proporcjonalną – wraz ze wzrostem zawartości białka w próbce mleka odnotowuje się tendencję do wyższej zawartości tłuszczu.
- **Tłuszcz vs Laktoza:** Uzyskany wynik $r_s \approx -0,10$ przy $p = 0,0281$ wskazuje, że zależność jest **statystycznie istotna** ($p < \alpha$). Jest to jednak korelacja bardzo słaba i ujemna, co sugeruje, że wyższe stężenia tłuszczu wiążą się z minimalnie niższą zawartością laktozy.
- **Białko vs Laktoza:** Wartość $r_s \approx 0,03$ przy $p = 0,4940$ jest statystycznie nieistotna. Ponieważ $p > \alpha$, nie ma podstaw do odrzucenia hipotezy o braku korelacji. Oznacza to, że zawartość białka nie wykazuje żadnej przewidywalnej, monotonicznej zależności względem zawartości laktozy w badanym materiale.

4.4 Analiza wpływu wieku mleka na skład mleka kobiecego

4.4.1 Wstęp

Skład mleka kobiecego ulega zmianom w trakcie laktacji, co może mieć istotne znaczenie dla rozwoju noworodka. W szczególności interesujące jest, w jaki sposób wraz z upływem czasu zmienia się zawartość podstawowych makroskładników, takich jak **białko**, **tłuszcz** oraz **laktoza**.

Celem niniejszej analizy jest zbadanie zależności pomiędzy wiekiem mleka, wyrażonym jako liczba dni od porodu (**Age of Milk [Days Since Birth]**), a jego składem chemicznym. Analizie poddano dane obserwacyjne obejmujące próbki mleka, dla których dostępne były następujące zmienne: zawartość **tłuszczu (Fat [g/dL])**, **białka (Protein [g/dL])** oraz **laktozy (Lactose [g/dL])**.

W analizie zastosowano współczynnik korelacji **rang Spearmana** (rozdział 3.3) do oceny zależności między wiekiem mleka a zawartością analizowanych składników. Następnie wykorzystano **regresję liniową** (rozdział 3.4) oraz porównano modele na podstawie R^2 i **RMSE** (rozdział 3.6).

Do wizualnej oceny przebiegu zależności zastosowano wygładzanie **LOESS** (rozdział 3.5). Różnice między grupami wieku mleka oceniono testem **Kruskala-Wallisa** (rozdział 3.7). Analizę przeprowadzono w programie R.

4.4.2 Statystyka opisowa

Zmienna	Min	Q1	Mediana	Średnia	Q3	Max
Wiek mleka [dni]	1.0	35.8	84.0	106.4	157.0	348.0
Tłuszcz	0.2	3.0	3.5	3.505	3.9	7.1
Białko	0.6	0.9	1.0	1.070	1.2	2.1
Laktoza	6.3	7.1	7.2	7.215	7.3	8.2

Tabela 7: Statystyki opisowe dla danych do 350 dni

4.4.3 Hipotezy

Dla każdej analizowanej zmiennej (białko, tłuszcz, laktoza) sformułowano następujące hipotezy statystyczne dotyczące zależności od wieku mleka:

- $H_0 : r_s = 0$ (brak zależności między wiekiem mleka a daną zmienną),
- $H_1 : r_s \neq 0$ (istnieje zależność między wiekiem mleka a daną zmienną).

4.4.4 Analiza białka

Dla zawartości białka obliczono współczynnik korelacji rang Spearmana (rozdział 3.3) w celu oceny zależności pomiędzy wiekiem mleka a zawartością białka. Analizę przeprowadzono dla próbek o wieku mleka do 350 dni. Otrzymano:

$$r_s = -0,5979, \quad p < 0,001$$

Na podstawie wartości p odrzucono hipotezę zerową H_0 o braku zależności między wiekiem mleka a zawartością białka. Wartość współczynnika r_s wskazuje na umiarkowaną ujemną zależność. Oznacza to, że większemu wiekowi mleka odpowiada zwykle niższa zawartość białka.

W celu ilościowego opisu ogólnego trendu zastosowano pomocniczo regresję liniową. Model regresji miał postać:

$$\hat{y} = 1,1921 - 0,001147x$$

gdzie: x – wiek mleka [dni], $\hat{y}$ – przewidywana zawartość białka.

Dla modelu liniowego otrzymano: $R^2 = 0,2509$, $RMSE = 0,1737$. Nachylenie modelu było istotne statystycznie ($p < 0,001$). Oznacza to, że wiek mleka istotnie wpływa na zawartość białka, jednak model liniowy wyjaśnia jedynie około 25,1% zmienności tej cechy.


Dodatkowo porównano kilka modeli regresyjnych, wykorzystując współczynnik determinacji R^2 oraz błąd RMSE.

Model	R^2	RMSE
Kwadratowy	0,4012	0,1553
Sześcienny	0,4319	0,1513
Logarytmiczny	0,4271	0,1519
Wykładniczy	0,2536	0,1557

Tabela 8: Porównanie modeli regresyjnych dla zawartości białka.


Najniższą wartość RMSE uzyskał model sześcienny ($RMSE = 0,1513$), jednak model logarytmiczny osiągnął bardzo zbliżone dopasowanie ($RMSE = 0,1519$). Oba modele charakteryzowały się wyraźnie wyższymi wartościami współczynnika determinacji niż model liniowy ($R^2 \approx 0,43$), co wskazuje na częściowo nieliniowy charakter zależności pomiędzy wiekiem mleka a zawartością białka.

Na wykresie przedstawiono punkty pomiarowe oraz krzywą LOESS. Krzywa ta wskazuje, że zawartość białka gwałtownie maleje w początkowym okresie laktacji, a następnie stabilizuje się na poziomie około 0,9–1,0. Przebieg zależności nie ma charakteru liniowego.



Rysunek 15: Zależność zawartości białka od wieku mleka.

Histogram rozkładu zawartości białka wskazuje, że większość obserwacji koncentruje się w zakresie około 0,9–1,2. Widoczna jest prawostronna asymetria rozkładu, wynikająca z obecności mniejszej liczby próbek o podwyższonej zawartości białka.



Rysunek 16: Histogram zawartości białka.

Wniosek: zawartość białka istotnie zależy od wieku mleka ($r_s = -0,5979$, $p < 0,001$). Zależność ma charakter nieliniowy: największy spadek obserwowany jest w początkowym okresie laktacji, po czym zawartość białka ulega względnej stabilizacji.

4.4.5 Analiza tłuszczu

Analogicznie jak w przypadku białka, dla zawartości tłuszczu przeprowadzono analizę zależności od wieku mleka z wykorzystaniem współczynnika korelacji rang Spearmana oraz modeli regresyjnych. Analizę wykonano dla próbek o wieku mleka do 350 dni. Otrzymano:

$$r_s = 0,1047, \quad p < 0,001$$

Na podstawie wartości p odrzucono hipotezę zerową H_0 o braku zależności między wiekiem mleka a zawartością tłuszczu. Wartość współczynnika r_s wskazuje jednak na bardzo słabą dodatnią zależność. Oznacza to, że wraz ze wzrostem wieku mleka zawartość tłuszczu wykazuje jedynie niewielką tendencję wzrostową.

W celu ilościowego opisu ogólnego trendu zastosowano pomocniczo regresję liniową. Model regresji miał postać:

$$\hat{y} = 3,3731 + 0,001244x$$

gdzie: x – wiek mleka [dni], $\hat{y}$ – przewidywana zawartość tłuszczu.

Dla modelu liniowego otrzymano: $R^2 = 0,0174$, $RMSE = 0,8202$. Nachylenie modelu było istotne statystycznie ($p < 0,001$). Niska wartość R^2 wskazuje jednak, że wiek mleka wyjaśnia jedynie około 1,7% zmienności zawartości tłuszczu.


Dodatkowo porównano kilka modeli regresyjnych, wykorzystując współczynnik determinacji R^2 oraz błąd RMSE.

Model	R^2	RMSE
Kwadratowy	0,0281	0,8158
Sześcienny	0,0292	0,8153
Logarytmiczny	0,0056	0,8251
Wykładniczy	0,0049	0,2680

Tabela 9: Porównanie modeli regresyjnych dla zawartości tłuszczu.


Najniższą wartość RMSE uzyskał model sześcienny ($RMSE = 0,8153$), jednak różnice pomiędzy modelem kwadratowym i sześciennym były bardzo niewielkie. Jednocześnie wszystkie modele charakteryzowały się bardzo niskimi wartościami współczynnika determinacji ($R^2 < 0,03$), co wskazuje, że wiek mleka wyjaśnia jedynie znikomą część zmienności zawartości tłuszczu.

Na wykresie przedstawiono punkty pomiarowe oraz krzywą LOESS. Widoczny jest jedynie bardzo łagodny trend wzrostowy, przy dużym rozproszeniu obserwacji w całym zakresie wieku mleka. W przeciwieństwie do zawartości białka, nie obserwuje się gwałtownych zmian w początkowym okresie laktacji.



Rysunek 17: Zależność zawartości tłuszczu od wieku mleka.

Histogram rozkładu zawartości tłuszczu wskazuje, że większość obserwacji koncentruje się w zakresie około 2,5–4,5. Rozkład jest względnie zbliżony do symetrycznego, choć widoczne są pojedyncze obserwacje o podwyższonej zawartości tłuszczu.



Rysunek 18: Histogram zawartości tłuszczu.

Wniosek: zawartość tłuszczu wykazuje istotną statystycznie, lecz bardzo słabą dodatnią zależność od wieku mleka ($r_s = 0,1047$, $p < 0,001$). Bardzo niskie wartości R^2 dla modeli regresyjnych wskazują, że wiek mleka wyjaśnia jedynie znikomą część zmienności zawartości tłuszczu. Zmienność tej cechy jest prawdopodobnie w większym stopniu związana z dodatkowymi czynnikami biologicznymi i indywidualnymi niż z samym wiekiem mleka.

4.4.6 Analiza laktozy

Analogicznie przeprowadzono analizę zawartości laktozy, obejmującą korelację rang Spearmana oraz porównanie modeli regresyjnych względem wieku mleka. Analizę wykonano dla próbek o wieku mleka do 350 dni. Otrzymano:

$$r_s = -0,0913, \quad p = 0,00286$$

Na podstawie wartości p odrzucono hipotezę zerową H_0 o braku zależności między wiekiem mleka a zawartością laktozy. Wartość współczynnika r_s wskazuje jednak na bardzo słabą ujemną zależność. Oznacza to, że wraz ze wzrostem wieku mleka zawartość laktozy wykazuje jedynie minimalną tendencję spadkową.

W celu ilościowego opisu ogólnego trendu zastosowano pomocniczo regresję liniową. Model regresji miał postać:

$$\hat{y} = 7,226 - 0,000106x$$

gdzie: x – wiek mleka [dni], $\hat{y}$ – przewidywana zawartość laktozy.

Dla modelu liniowego otrzymano: $R^2 = 0,0019$, $RMSE = 0,2112$. Nachylenie modelu nie było istotne statystycznie ($p = 0,15014$). Oznacza to, że liniowy wpływ wieku mleka na zawartość laktozy nie został potwierdzony statystycznie.


Dodatkowo porównano kilka modeli regresyjnych, wykorzystując współczynnik determinacji R^2 oraz błąd RMSE.

Model	R^2	RMSE
Kwadratowy	0,0060	0,2107
Sześcienny	0,0107	0,2102
Logarytmiczny	0,0043	0,2109
Wykładniczy	0,0020	0,0289

Tabela 10: Porównanie modeli regresyjnych dla zawartości laktozy.


Najniższą wartość RMSE uzyskał model sześcienny ($RMSE = 0,2102$), jednak różnice pomiędzy modelami kwadratowym, sześciennym i logarytmicznym były bardzo niewielkie. Jednocześnie wszystkie modele charakteryzowały się bardzo niskimi wartościami współczynnika determinacji ($R^2 < 0,02$), co wskazuje, że wiek mleka wyjaśnia jedynie znikomą część zmienności zawartości laktozy.

Na wykresie przedstawiono punkty pomiarowe oraz krzywą LOESS. Krzywa LOESS pozostaje niemal pozioma w całym zakresie analizowanych danych, co wskazuje na względnie stabilną zawartość laktozy podczas laktacji. Obserwowane zmiany są znacznie mniejsze niż w przypadku białka.



Rysunek 19: Zależność zawartości laktozy od wieku mleka.

Histogram rozkładu zawartości laktozy wskazuje, że większość obserwacji koncentruje się w wąskim zakresie około 7,0–7,4. Rozkład jest zbliżony do symetrycznego i cechuje się niewielkim rozproszeniem danych, co potwierdza stosunkowo stabilną zawartość laktozy w analizowanych próbkach mleka.



Rysunek 20: Histogram zawartości laktozy.

Wniosek: zawartość laktozy pozostaje względnie stabilna wraz ze wzrostem wieku mleka. Pomiędzy istotności statystycznej korelacji rang Spearmana ($r_s = -0,0913$, $p = 0,00286$), siła zależności jest bardzo słaba. Bardzo niskie wartości R^2 dla modeli regresyjnych wskazują, że wiek mleka wyjaśnia jedynie znikomą część zmienności zawartości laktozy.

4.4.7 Test Kruskala–Wallisa

W celu oceny wpływu wieku mleka na zawartość białka, tłuszczu oraz laktozy przeprowadzono test Kruskala–Wallisa (rozdział 3.7). Analizę wykonano dla próbek o wieku mleka do 350 dni.

Próbki podzielono na cztery grupy wieku mleka:

- mleko młode (0–30 dni),
- mleko średnie (31–90 dni),
- mleko dojrzałe (91–200 dni),
- mleko późne (201–350 dni).

Hipotezy testowe miały postać:

- H_0 : rozkłady analizowanej zmiennej są jednakowe we wszystkich grupach,
- H_1 : co najmniej jedna grupa różni się od pozostałych.

Otrzymano następujące wyniki:


Zmienna	χ^2	df	p
Białko	388,98	3	$< 2,2 \cdot 10^{-16}$
Tłuszcz	21,96	3	$6,67 \cdot 10^{-5}$
Laktoza	16,39	3	$9,42 \cdot 10^{-4}$

Tabela 11: Wyniki testu Kruskala–Wallisa.

Dla wszystkich analizowanych składników uzyskano wartości $p < 0,05$, dlatego odrzucono hipotezę zerową o braku różnic pomiędzy grupami wieku mleka na korzyść hipotezy alternatywnej, że co najmniej jedna grupa różni się od pozostałych.

W kolejnym etapie wykonano test post-hoc Dunna z korekcją Bonferroniego (rozdział 3.8) w celu identyfikacji grup odpowiedzialnych za zaobserwowane różnice.

Dla zawartości białka stwierdzono istotne różnice pomiędzy większością grup. Nie wykazano jedynie różnicy pomiędzy grupami 91–200 dni oraz 201–350 dni ($p = 1.000$). Wyniki te wskazują na wyraźny spadek zawartości białka w początkowym okresie laktacji, po którym następuje stabilizacja.




Rysunek 21: Zawartość białka w grupach wieku mleka.

Dla zawartości tłuszczu istotne różnice stwierdzono pomiędzy grupą 201–350 dni a grupami 0–30 dni ($p = 0.017$) oraz 91–200 dni ($p = 0.031$). Pozostałe porównania nie były istotne statystycznie. Wyniki sugerują niewielki wzrost zawartości tłuszczu w późniejszym okresie laktacji.



Rysunek 22: Zawartość tłuszczu w grupach wieku mleka.

Dla zawartości laktozy istotne różnice wystąpiły pomiędzy grupą 0–30 dni a grupami 31–90 dni ($p = 0.005$) oraz 91–200 dni ($p < 0.001$). Pozostałe porównania nie wykazały istotnych różnic. Pomimo istotności statystycznej różnice były niewielkie, co potwierdzają niemal identyczne mediany oraz kwartyle we wszystkich grupach.



Rysunek 23: Zawartość laktozy w grupach wieku mleka.

Wniosek: Najsilniejszy wpływ wieku mleka zaobserwowano dla zawartości białka, dla którego mediany zmniejszały się wraz z postępem laktacji. Dla tłuszczu różnice pomiędzy grupami były niewielkie i dotyczyły głównie najpóźniejszego okresu laktacji. W przypadku laktozy uzyskano istotność statystyczną, jednak praktyczne znaczenie różnic było bardzo małe, ponieważ mediany i kwartyle pozostawały niemal identyczne we wszystkich grupach.

4.4.8 Wnioski końcowe

Na podstawie przeprowadzonej analizy stwierdzono, że:

- zawartość białka istotnie maleje wraz z wiekiem mleka, szczególnie w początkowym okresie laktacji;
- zawartość tłuszczu wykazuje bardzo słabą tendencję wzrostową;
- zawartość laktozy pozostaje względnie stabilna;
- zależności między wiekiem mleka a składem mleka mają częściowo nieliniowy charakter;
- test Kruskala–Wallisa wykazał istotne różnice między grupami wieku mleka, przy czym największe znaczenie miały różnice dla białka.

Największe zmiany zaobserwowano dla zawartości białka. Tłuszcz i laktoza wykazywały znacznie mniejszą zmienność względem wieku mleka, co sugeruje, że ich poziom może zależeć również od innych czynników biologicznych i indywidualnych.

4.5 Analiza zawartości składników mleka matki w zależności od czasu trwania ciąży i wyniku porodu

4.5.1 Opis i cel badania

Celem analizy jest sprawdzenie, czy istnieje istotna różnica w zawartości składników mleka matki w zależności od czasu trwania ciąży oraz wyniku porodu. Grupy badawcze zdefiniowano następująco:

- **Term** – poród w terminie,
- **Preterm** – poród przedwczesny,
- **Deceased** – dziecko zmarło przy porodzie lub urodziło się martwe.

Analizie poddano zawartość trzech kluczowych składników: **tłuszczu, białka oraz laktozy**.

4.5.2 Wstępne pomiary

Obliczono średnią zawartość ($\bar{S}$), odchylenie standardowe (Sd) oraz medianę (Med) tłuszczu, białka i laktozy dla każdej z grup (Term, Preterm, Deceased). Wyniki umieszczono w tabeli 1.

Grupa	Tłuszcz			Białko			Laktoza		
	$\bar{S}$	Sd	Med	$\bar{S}$	Sd	Med	$\bar{S}$	Sd	Med
Term	3,51	0,87	3,46	1,06	0,19	1,03	7,20	0,21	7,19
Preterm	3,61	0,69	3,62	1,11	0,23	1,05	7,24	0,22	7,22
Deceased	3,49	0,87	3,41	1,11	0,29	1,04	7,09	0,25	7,07

Tabela 12: Statystyki opisowe składników mleka matki (g/dL) w badanych grupach.

4.5.3 Dobór testu i hipotezy


Ponieważ badane grupy są skrajnie nierównoliczne, sugeruje to użycie nieparametrycznego testu Kruskala-Wallisa, aby porównać zawartość składników mleka. Test ten służy do porównywania trzech lub więcej niezależnych grup pod względem zmiennej ilościowej, gdy nie są spełnione założenia o normalności rozkładu lub równości wariancji.

Mechanizm działania testu polega na uporządkowaniu wszystkich obserwacji od najmniejszej do największej i nadaniu im kolejnych rang. Następnie rangi te są sumowane w obrębie poszczególnych grup. Pozwala to sprawdzić, czy w którejś z grup kumulują się wartości istotnie wyższe lub niższe niż w pozostałych. W przypadku uzyskania wyników istotnych statystycznie, różnice między konkretnymi parami grup weryfikowano testem post-hoc Dunna z korektą Bonferroniego.


4.5.4 Sprawdzenie założeń statystycznych

Weryfikacja normalności rozkładów testem Shapiro-Wilka wykazała, że w większości podgrup (składnik $\times$ grupa kliniczna) dane nie spełniały założenia o rozkładzie normalnym ($W \neq 1, p < 0,05$).


Wyniki zilustrowano na poniższych histogramach.



Rysunek 24: Histogramy rozkładu laktozy w 3 badanych grupach z nałożoną krzywą gęstości.




Rysunek 25: Histogramy rozkładu białka w 3 badanych grupach z nałożoną krzywą gęstości.



Rysunek 26: Histogramy rozkładu tłuszczu w 3 badanych grupach z nałożoną krzywą gęstości.

Jednorodność wariancji (homoskedastyczność) zweryfikowano przy użyciu testu Levene’a i otrzymano następujące wyniki:


- Dla **laktozy** stwierdzono jednorodność wariancji ($p \approx 0,248$).
- Dla **białka** oraz **tłuszczu** wykazano brak homoskedastyczności (odpowiednio $p \approx 0,024$ oraz $p \approx 0,045$).



Rysunek 27: Wykres reszt laktozy w badanych grupach.



Rysunek 28: Wykres reszt białka w badanych grupach.



Rysunek 29: Wykres reszt tłuszczu w badanych grupach.

Wniosek: W związku z występowaniem heteroskedastyczności dla większości parametrów oraz stwierdzonym brakiem normalności rozkładów, do analizy istotności różnic między grupami zastosowano nieparametryczny test Kruskala-Wallisa, który jest odporny na powyższe uwarunkowania i pozwala na rzetelne porównanie rozkładów rangowych.

4.5.5 Hipotezy statystyczne

Dla każdego z badanych parametrów (tłuszcz, białko, laktoza) przyjęto następujące hipotezy:

H_0 : Rozkłady zawartości danego składnika w mleku matki są jednakowe we wszystkich trzech grupach (Term, Preterm, Deceased).

H_1 : Istnieje co najmniej jedna para grup, między którymi występują istotne statystycznie różnice w rozkładzie (rangach) zawartości składnika.

4.5.6 Wyniki analizy statystycznej

W programie R przeprowadzono test Kruskala-Wallisa dla każdego z badanych składników mleka. Uzyskano następujące wyniki:

- **Tłuszcz:** $p = 0,068$

Wniosek: Wartość $p > 0,05$, co oznacza formalny brak podstaw do odrzucenia hipotezy H_0 . Jednak przez to, że wynik znajduje się blisko progu istotności możemy przypuszczać, że przy większej liczebności grupy 3 różnica ta osiągnęłaby poziom istotności.

-
- **Białko:** $p = 0,179$

Wniosek: Wynik nieistotny statystycznie ($p > 0,05$). Różnice w zawartości białka między badanymi grupami są zbyt małe w stosunku do rozrzutu danych, aby uznać je za wynikające z czynnika innego niż losowy. Stąd brak podstaw do odrzucenia H_0 .

- **Laktoza:** $p = 0,003$

Wniosek: Wynik jest wysoce istotny statystycznie ($p < 0,05$). Czas trwania ciąży oraz wynik porodu mają istotny wpływ na zawartość laktozy w mleku kobiecym. Odrzucamy zatem H_0 na rzecz H_1 , co stanowi podstawę do dalszej analizy tego składnika testami post-hoc.

4.5.7 Dalsza analiza dla laktozy

Analiza post-hoc (Test Dunna z korektą Bonferroniego) dla laktozy

Podobnie jak test Kruskala-Wallisa, test Dunna nie bazuje na surowych średnich arytmetycznych, lecz na różnicach w średnich rangach przypisanych poszczególnym obserwacjom. Pozwala to na uniknięcie błędów wynikających z obecności odstających obserwacji.


Korekta Bonferroniego polega na dostosowaniu wartości poziomu istotności poprzez przemnożenie uzyskanych wartości p przez liczbę wykonanych porównań (w tym przypadku przez 3), otrzymując tym sposobem skorygowany poziom istotności (p_{adj}).

W celu zidentyfikowania różniących się między sobą grup przeprowadzono porównania parami. Wyniki opisano poniżej:

- **Grupa 1 vs Grupa 2 (Term vs Preterm):** $p_{adj} = 0,233$. Brak istotnych statystycznie różnic w zawartości laktozy pomiędzy mlekiem matek rodzących w terminie a matek wcześniaków.
- **Grupa 1 vs Grupa 3 (Term vs Deceased):** $p_{adj} = 0,016$. Istotnie niższa zawartość laktozy w grupie matek po stracie dziecka w porównaniu do grupy rodzącej w terminie.
- **Grupa 2 vs Grupa 3 (Preterm vs Deceased):** $p_{adj} = 0,003$. Wysoce istotna statystycznie różnica – zawartość laktozy w grupie Deceased była znacząco niższa niż w grupie Preterm.


Podsumowanie: Głównym źródłem istotności statystycznej w teście Kruskala-Wallisa dla laktozy jest grupa 3 (Deceased), której wyniki znacząco odbiegają od pozostałych dwóch grup, charakteryzujących się zbliżonym poziomem tego składnika.

4.5.8 Wizualizacja graficzna wyników




Rysunek 30: Zawartość laktozy [g/dL] w zależności od grupy badawczej.

- Mediana dla grupy 1 (Term) oraz 2 (Preterm) znajduje się na podobnym poziomie (ok. 7,2 g/dL).
- Mediana dla grupy 3 (Deceased) jest wyraźnie obniżona względem pozostałych dwóch grup (7,07 g/dL).
- Wizualizacja zawartości laktozy potwierdza tendencję spadkową tego składnika w grupie matek po stracie dziecka.



Rysunek 31: Zawartość białka [g/dL] w zależności od grupy badawczej.

- Mediany we wszystkich trzech grupach znajdują się niemal na tym samym poziomie (ok. 1,0 g/dL).
- Sugeruje to, że zawartość białka w mleku jest bardzo stabilna i nie zależy od tego, czy poród był w terminie, przedwczesny, czy nastąpiła strata dziecka.
- Stąd czynniki, które różnicowały laktozę, nie mają wpływu na poziom białka.



Rysunek 32: Zawartość tłuszczu [g/dL] w zależności od grupy badawczej.

- Tłuszcz ma bardzo duży rozrzut – od niemal 0 do ponad 6 g/dL. Możemy wywnioskować, że jest to najbardziej zmienny składnik mleka.
- Widać również tendencję do nieco wyższej zawartości tłuszczu w mleku matek wcześniaków, ale zgodnie z otrzymaną wartością p , jest to statystycznie nieistotna różnica.
- Grupa 3 wygląda bardzo podobnie do grupy 1, co oznacza, że w przypadku tłuszczu grupa matek po stracie nie wyróżnia się negatywnie (w przeciwieństwie do laktozy).

4.6 Analiza zmiany składu mleka w czasie w zależności od czasu trwania ciąży i wyniku porodu

4.6.1 Opis i cel badania

Celem analizy jest sprawdzenie, jak zmienia się zawartość składników mleka matki w czasie w zależności od wyniku porodu. Wiek mleka liczony jest jako dni, które minęły od porodu w momencie pobrania mleka do badań. Grupy badawcze zdefiniowano następująco:

- **Term** – poród w terminie,
- **Preterm** – poród przedwczesny,
- **Deceased** – dziecko zmarło przy porodzie lub urodziło się martwe.

Analizie poddano zawartość trzech kluczowych składników: **tłuszczu, białka oraz laktozy**.

4.6.2 Metodyka

W celu zbadania dynamiki zmian składników mleka w zależności od czasu trwania laktacji, przeprowadzono analizę korelacji rangowej Spearmana pomiędzy dniem laktacji a zawartością poszczególnych makroskładników. Analizę wykonano niezależnie dla każdej z trzech grup badawczych, co pozwoliło na identyfikację odmiennych wzorców zmian czasowych w zależności od statusu porodu i straty dziecka.

4.6.3 Wyniki


Składnik	Grupa	Współczynnik ρ	Wartość p
Laktoza	1 (Term)	-0,140	< 0,001
	2 (Preterm)	0,035	0,669
	3 (Deceased)	0,140	0,545
Białko	1 (Term)	-0,501	< 0,001
	2 (Preterm)	-0,657	< 0,001
	3 (Deceased)	-0,596	0,004
Tłuszcz	1 (Term)	0,129	< 0,001
	2 (Preterm)	0,237	0,003
	3 (Deceased)	-0,031	0,893


Tabela 13: Współczynniki korelacji rangowej Spearmana (ρ) pomiędzy czasem laktacji a zawartością składników mleka.

4.6.4 Wnioski

Na podstawie przeprowadzonego testu korelacji rangowej Spearmana dla poszczególnych składników mleka (laktoza, białko, tłuszcz) w zależności od dnia laktacji, a następnie wykonanych wizualizacji, opisano zauważone zależności oraz wyciągnięto następujące wnioski.


4.6.5 Laktoza







- Zaobserwowano słabą ujemną korelację jedynie w grupie 1 ($\rho = -0,14, p < 0,001$), zatem wraz z wiekiem mleka, zawartość laktozy powoli spada, co wyraźnie widać na wykresie.
- W grupach 2 i 3 poziom laktozy pozostawał stabilny w czasie laktacji, o czym świadczą nieistotne statystycznie wyniki testu (odpowiednio $p = 0,669$ oraz $p = 0,545$).

4.6.6 Białko








- Odnotowano silną i wysoce istotną statystycznie ujemną korelację we wszystkich badanych grupach (Grupa 1: $\rho = -0,50$; Grupa 2: $\rho = -0,66$; Grupa 3: $\rho = -0,60$).
- Świadczy to o ogólnym malejącym trendzie dla całego zbioru danych, natomiast dopasowane modele matematyczne dla grupy 1 i 2 opisane kolejno wzorami $y = x^3$ oraz $y = x^2$, wskazują na spadek, a następnie ponowny wzrost wartości. Różnice te wynikają z tego, że model dopasowuje się do pojedynczych odległych punktów. Korelacja Spearmana, operując na rangach, niweluje wpływ tych ekstremalnych wartości, dlatego jej wynik jest bardziej wiarygodnym wskaźnikiem ogólnego zachowania się składników mleka w całym badanym procesie.
- Stąd możemy stwierdzić stopniowy spadek zawartości białka wraz z upływem czasu laktacji. Zgadza się to z biologicznym faktem, że w siarze, czyli mleku z pierwszych dni po

porodzie, występuje znacznie więcej białka niż w mleku dojrzłym.

4.6.7 Tłuszcz





- Wykazano istotną dodatnią korelację w grupie 1 ($\rho = 0,13, p < 0,001$) oraz grupie 2 ($\rho = 0,24, p = 0,003$), co wskazuje na stopniowy wzrost kaloryczności mleka w tych grupach.
- W grupie 3 nie stwierdzono istotnej zależności czasowej ($p = 0,893$), co sugeruje większą niestabilność tego parametru w tej grupie.

4.6.8 Ocena jakości modeli dla białka

Jako, że białko jest jedynym z badanych składników, który w każdej grupie wykazał widoczną zależność na przestrzeni czasu, dokonano analizy możliwych pasujących modeli, aby znaleźć najlepsze dopasowanie do danych.

4.6.9 Metodyka

Jako pierwszy krok, przefiltrowano dane otrzymując tylko wyniki gdzie wiek mleka jest co najwyżej równy 600 dni, aby wyeliminować kilka odstających rekordów, które mogłyby spowodować nadmierne dopasowanie modeli.

W programie R podzielono dane na część treningową (80%) oraz testową (20%). Następnie zbudowano modele wykorzystujące możliwe pasujące funkcje i wykonano prognozy. Na podstawie wyników policzono RMSE (pierwiastek z błędu średniokwadratowego) i R^2 (współczynnik determinacji). Analogiczną analizę wykonano również dla każdej z grup z osobna (Term, Preterm, Deceased). Wyniki umieszczono w tabelach poniżej.

Model	RMSE	R^2
Kwadratowy (x^2)	0.1553668	0.3635543
Sześcienny (x^3)	0.1627596	0.3015460
Logarytmiczny ($\log(x)$)	0.1687373	0.2492987

Tabela 14: Porównanie miar dopasowania modeli dla całego zbioru danych

Model	RMSE	R^2
Kwadratowy (x^2)	0.1438601	0.2897567
Sześcienny (x^3)	0.1355537	0.3694075
Logarytmiczny ($\log(x)$)	0.1405469	0.3220946

Tabela 15: Porównanie miar dopasowania modeli dla grupy 1 (Term)

Model	RMSE	R^2
Kwadratowy (x^2)	0.2104348	0.2881934
Sześcienny (x^3)	0.2321641	0.1336031
Logarytmiczny ($\log(x)$)	0.2379827	0.08963054

Tabela 16: Porównanie miar dopasowania modeli dla grupy 2 (Preterm)

Model	RMSE	R^2
Kwadratowy (x^2)	1.63877677	-94.0987708
Sześcienny (x^3)	4.03548750	-575.6699499
Logarytmiczny ($\log(x)$)	0.09445774	0.6840558

Tabela 17: Porównanie miar dopasowania modeli dla grupy 3 (Deceased)

4.6.10 Wnioski

Najlepsze dopasowanie wykazują modele, które mają najmniejszy pierwiastek błędu średniokwadratowego (RMSE), a współczynnik dopasowania (R^2) jak najbliższy 1. Zgodnie z tym wysunięto poniższe wnioski:

- dla całości danych lepszym wyborem okazał się model $y = x^2$,
- dla grupy 1: $y = x^3$,
- dla grupy 2: $y = x^2$,
- dla grupy 3 modele $y = x^2$ i $y = x^3$ okazały się skrajnie nieodpowiednie, w przeciwieństwie do modelu opisanego wzorem $y = \log(x)$, który wykazał bardzo dobre dopasowanie.

4.7 Analiza porównawcza gęstości energetycznej mleka (Term vs Preterm)

4.7.1 Cel analizy

Wykazanie, czy stopień dojrzałości noworodka w momencie porodu (poród o czasie (Term)/poród przedwczesny (Preterm)) ma wpływ na gęstość energetyczną mleka matki.

4.7.2 Wyznaczenie wartości energetycznej mleka

Gęstość energetyczna mleka nie była bezpośrednio podana w bazie danych, natomiast została wyznaczona na podstawie zawartości makroskładników. Zastosowano wzór uwzględniający kaloryczność tłuszczu, białka oraz laktozy:

$$\text{Energia (kcal/dL)} = (\text{Fat} \cdot 9) + (\text{Protein} \cdot 4) + (\text{Lactose} \cdot 4)$$

Wzór został opracowany na podstawie dostępnej bibliografii [14].

4.7.3 Metoda statystyczna


Do porównania dwóch niezależnych grup wykorzystano test t-Studenta dla prób niezależnych.

4.7.4 Weryfikacja założeń o normalności rozkładu

Test normalności przeprowadzony testem Shapiro-Wilka:

- Term: $p = 0.0000$
- Preterm: $p = 0.0169$

Pomimo formalnego wyniku testu Shapiro-Wilka zdecydowano kontynuować test t-Studenta, ponieważ przy tak licznej grupie test i tak zadziała poprawnie.



Rysunek 33: Gęstość energetyczna mleka: Term vs Preterm

4.7.5 Wyniki i interpretacja

Średnie wartości gęstości energetycznej:

- **Preterm:** ok. 65,86 kcal/dL
- **Term:** ok. 64,68 kcal/dL

Interpretacja wizualna: Duża część wyników w obu grupach Term oraz Preterm jest do siebie bardzo zbliżona.

Istotność statystyczna: $p = 0.0796$. Uzyskana wartość jest wyższa od progu istotności $\alpha = 0.05$. Oznacza to, że różnica pomiędzy grupami nie jest istotna statystycznie.

5 Wnioski

5.1 Wnioski z etapu przygotowania i obróbki danych

Doświadczenia zebrane podczas pracy z pierwotną bazą MilkyBase wyraźnie pokazują, że rzeczywiste, obszerne zbiory danych biologicznych i medycznych rzadko są gotowe do bezpośredniej analizy statystycznej. Etap zrozumienia, czyszczenia i przygotowania danych stanowił kluczowy element naszego projektu. Z tej fazy prac płyną następujące wnioski ogólne:

- **Problem agregacji informacji:** Zapisywanie wielu różnych parametrów, warunków i jednostek w pojedynczych komórkach arkusza kalkulacyjnego uniemożliwia wykorzystanie standardowych metod analitycznych. Dopiero deagregacja, przeprowadzona przy użyciu oprogramowania SAS, pozwoliła na rozbitcie tych informacji na odrębne, gotowe do zrozumienia zmienne.
- **Zjawisko rzadkości danych (braki danych):** Zwiększenie rozmiarów bazy (po deagregacji do ponad 700 kolumn) ujawniło różnice w kompletności informacji. Ponad 500 badanych cech posiadało mniej niż 10 obserwacji. Wymusiło to konieczność redukcji analizowanego zbioru i skupienia się wyłącznie na najlepiej udokumentowanych makroskładnikach (białko, tłuszcz, laktoza).
- **Niespójność formatów i struktury:** Obecność odwołań tekstowych (np. *!John_026_Prot*) w miejscach, w których spodziewamy się wartości liczbowych stanowi przeszkodę w badaniach. Próba analizy danych z różnych, niejednorodnych metodologicznie badań niesie ryzyko wyciągnięcia błędnych wniosków.

Podsumowując, powyższe trudności skłoniły nas do odrzucenia niespójnych fragmentów bazy na rzecz wyselekcjonowania rzetelnego, jednorodnego podzbioru (pochodzącego z artykułu z *PLOS ONE*) [2]. Wniosek jest jednoznaczny: jakość i wiarygodność wyników analizy statystycznej zależy w pierwszej kolejności od świadomej selekcji oraz właściwego przygotowania materiału, który będziemy poddawać analizie.

5.2 Wnioski z analizy statystycznej

Na podstawie przeprowadzonych analiz statystycznych sformułowaliśmy następujące wnioski końcowe dotyczące składu mleka kobiecego:

- **Rozkład makroskładników:** Nasze badania pokazały, że żaden z głównych makroskładników (białko, tłuszcz, laktoza) nie ma rozkładu normalnego. Dane były często asymetryczne (np. wyraźne skupienie wyników wokół jednej wartości dla laktozy), co w pewnych przypadkach wymuszało konieczność korzystania z testów nieparametrycznych w dalszej części projektu.
- **Wpływ wieku matki:** Gdy podzieliliśmy pacjentki na dwie szerokie grupy (poniżej i powyżej 30 lat), nie zauważyliśmy żadnych istotnych różnic w składzie ich mleka. Taka różnica pojawiła się dopiero, gdy porównane zostały ze sobą skrajne grupy wiekowe – okazało się, że matki starsze (powyżej 35. roku życia) mają w mleku nieco więcej białka niż matki bardzo młode (do 25 lat).
- **Dynamika laktacji (wiek mleka):** Czas, jaki upłynął od porodu, okazał się czynnikiem najsilniej wpływającym na zawartość białka. Tuż po porodzie jest go najwięcej, a z czasem jego poziom dość szybko spada, by później się ustabilizować. Zmiany te nie mają jednak prostego, liniowego charakteru, co potwierdziły nasze wykresy i ocena dopasowania modeli.
- **Stabilność tłuszczu i laktozy w czasie:** W przeciwieństwie do białka, poziom tłuszczu i laktozy zmienia się w czasie tylko w minimalnym stopniu. Choć nasze testy wykazywały bardzo słabe trendy (lekki wzrost dla tłuszczu i spadek dla laktozy), to modele regresji pokazały, że sam upływ czasu niemal w ogóle nie tłumaczy tych zmian. Ich poziom prawdopodobnie zależy od innych, indywidualnych cech organizmu matki.
- **Wpływ dojrzałości noworodka i wyniku porodu:** Sprawdzając, czy czas trwania ciąży i wynik porodu wpływają na skład mleka, zauważyliśmy istotne różnice tylko w przypadku laktozy. Jej poziom był zauważalnie niższy u matek, które straciły dziecko (grupa Deceased). Z kolei zawartość tłuszczu i białka pozostawała na bardzo zbliżonym poziomie bez względu na to, czy poród nastąpił w terminie, był przedwczesny, czy zakończył się śmiercią dziecka.
- **Gęstość energetyczna:** Nasze obliczenia nie potwierdziły, aby przedwczesny poród znacząco wpływał na kaloryczność mleka. Mleko matek wcześniaków było wprawdzie minimalnie bardziej kaloryczne, ale różnica ta nie okazała się statystycznie istotna. Co więcej, zauważyliśmy, że w ciągu całego pierwszego roku laktacji gęstość energetyczna mleka jest bardzo stabilna i wzrasta tylko nieznacznie.

Podsumowując, największy wpływ na skład mleka ma czas, jaki upłynął od porodu – jednak zjawisko to dotyczy przede wszystkim białka. Poziom tłuszczu, laktozy oraz ogólna kaloryczność mleka są parametrami znacznie bardziej stabilnymi. Nie zmieniają się one drastycznie z upływem czasu i nie zależą w tak dużym stopniu ani od wieku matki, ani od momentu rozwiązania ciąży.

6 Bibliografia

- [1] L. Gajek, M. Kałuszka, Wnioskowanie statystyczne, Wydawnictwa Naukowo-Techniczne, Warszawa, 1996.
- [2] Macronutrient Variability in Human Milk From Donors to a Milk Bank: Implications for Feeding Preterm Infants.
<https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0210610>
- [3] Majewski, J. Wykład 7: Testy nieparametryczne. Statystyka w medycynie. Akademia Górniczo-Hutnicza im. Stanisława Staszica w Krakowie.
<https://kompilatory.agh.edu.pl/statwmed/wyklady/WFiIS-STATwMED-7-\Testy-nieparametryczne.pdf>
- [4] W. Kordecki, Rachunek prawdopodobieństwa i statystyka matematyczna, Oficyna Wydawnicza GiS, Wrocław, 2010.
- [5] Wikipedia, *Współczynnik korelacji rang Spearmana*.
https://pl.wikipedia.org/wiki/Wsp%C3%B3%C5%82czynnik_korelacji_rang_Spearmana
- [6] Mfiles, *Współczynnik korelacji rang Spearmana*.
https://mfiles.pl/pl/index.php/Wsp%C3%B3%C5%82czynnik_korelacji_rang_Spearmana
- [7] Wikipedia, *Regresja liniowa*.
<https://pl.wikipedia.org/wiki/Regresja liniowa>
- [8] Wikipedia contributors, *Local regression*, https://en.wikipedia.org/wiki/Local_regression
- [9] Data Science, *Metryki regresji*.
https://datascience.com.pl/uczenie_maszynowe_wstep/metryki_ml/regresja.html
- [10] Srivastava, S., *Evaluating Model Performance: Understanding MAE, MSE, RMSE and R^2 Score*.
<https://medium.com/@srivastavashivansh8922/evaluating-model-performance-understanding-mae-mse-rmse-and-r%C2%B2-score-5516e10fe8d6>
- [11] Naukowiec.org, *Test Kruskala-Wallis*.
https://www.naukowiec.org/wzory/statystyka/test-kruskala-wallisa_121.html
- [12] ANOVA Kruskala-Wallis
https://manuals.pqstat.pl/statpqpl:porown3grpl:nparpl:anova_kwpl
- [13] P. Biecek, Przewodnik po pakiecie R, Oficyna Wydawnicza GiS, Wrocław, 2017.

-
- [14] Zapotrzebowanie kaloryczne – jak je obliczyć i od czego zależy?
<https://ostrovit.com/pl/blog/zapotrzebowanie-kaloryczne-jak-je-obliczyc\ -od-czego-zalezy-1620652901.html>
- [15] MilkyBase, a database of human milk composition as a function of maternal-, infant- and measurement conditions.
<https://pmc.ncbi.nlm.nih.gov/articles/PMC9463137/>
- [16] MilkyBase, a database of human milk composition as a function of maternal-, infant- and measurement conditions. Figshare.
https://figshare.com/collections/MilkyBase_a_database_of_human_milk_composition_as_a_function_of_maternal-_infant-_and_measurement_conditions/6160191/1
- [17] ANOVA czyli analiza wariancji w pracy magisterskiej. Poradnik od a do z
https://magisterna5.pl/anova-analiza-wariancji-w-pracy-magisterskiej/#Krok_4-_Testy_post_hoc_%E2%80%93czyli_kto_sie_rozni_od_kogo